

GMU Numerical Analysis — Enero 2014

ENUNCIADO — PROBLEMA 1

1. Suppose you have a large set of data (x_j, f_j) , $j = 0, 1, \dots, n$, available at equidistant points $x_j = j/n$ on the interval $[0, 1]$. Suppose you want to approximate these data with a polynomial of degree k where $1 \ll k \ll n$.
- (a) Formulate a least squares problem for the polynomial t of the form $Ay = b$. Explain how you will define the entries of the matrix A and the vector b .
- (b) Derive a formula for the solution of the least squares problem.

SOLUCIÓN — PROBLEMA 1

Problema 1 — Ajuste polinomial por mínimos cuadrados

(a) **Formulación del problema** $Ay = b$.

Se tienen $n + 1$ datos (x_j, f_j) , $j = 0, \dots, n$, con $x_j = j/n \in [0, 1]$, y se busca el polinomio de grado $k \ll n$

$$p(x) = \sum_{i=0}^k y_i x^i$$

que mejor aproxima los datos en el sentido de mínimos cuadrados. Como hay $n + 1$ condiciones $p(x_j) \approx f_j$ y solo $k + 1$ incógnitas $y_0, \dots, y_k$ (con $k + 1 \leq n + 1$, en general $k + 1 < n + 1$), el sistema

$$p(x_j) = \sum_{i=0}^k y_i x_j^i = f_j, \quad j = 0, \dots, n,$$

está **sobredeterminado**. En forma matricial $Ay = b$ con

$$A = (a_{ji}) \in \mathbb{R}^{(n+1) \times (k+1)}, \quad a_{ji} = x_j^i \quad (j = 0, \dots, n, \quad i = 0, \dots, k), \quad b = (f_0, f_1, \dots, f_n)^T \in \mathbb{R}^{n+1}.$$

A es una matriz tipo Vandermonde rectangular (alta y delgada, pues $k + 1 \ll n + 1$). Se busca $y \in \mathbb{R}^{k+1}$ que minimice $\|Ay - b\|_2^2$, pues en general el sistema no tiene solución exacta.

(b) **Solución del problema de mínimos cuadrados.**

Rango completo de A . Si $Ay = 0$ con $y \neq 0$, entonces el polinomio $q(x) = \sum_{i=0}^k y_i x^i$ (de grado $\leq k$, no idénticamente nulo) se anularía en los $n + 1$ puntos distintos $x_0, \dots, x_n$. Pero un polinomio no nulo de grado $\leq k$ tiene a lo más k raíces, y $n + 1 > k$ (pues $k \ll n$). Contradicción. Luego A tiene rango columna completo $k + 1$, y $A^T A \in \mathbb{R}^{(k+1) \times (k+1)}$ es invertible (de hecho SPD).

Ecuaciones normales. Sea $\phi(y) = \|Ay - b\|_2^2 = (Ay - b)^T (Ay - b) = y^T A^T A y - 2y^T A^T b + b^T b$. Como ϕ es cuadrática convexa (su Hessiano es $2A^T A \succeq 0$), su mínimo se alcanza donde el gradiente se anula:

$$\nabla_y \phi(y) = 2A^T A y - 2A^T b = 0 \implies A^T A y = A^T b.$$

Por la invertibilidad de $A^T A$:

$$\boxed{y = (A^T A)^{-1} A^T b.}$$

Verificación dimensional: $A^T \in \mathbb{R}^{(k+1) \times (n+1)}$, así $A^T A \in \mathbb{R}^{(k+1) \times (k+1)}$ y $A^T b \in \mathbb{R}^{k+1}$: la fórmula produce efectivamente un vector $y \in \mathbb{R}^{k+1}$, como se requiere.

Nota numérica. En la práctica, para k moderado, resolver $A^T A y = A^T b$ directamente puede estar mal condicionado ($\kappa(A^T A) = \kappa(A)^2$); es preferible usar la factorización $A = QR$ (Householder o Gram-Schmidt) y resolver el sistema triangular $R_1 y = Q_1^T b$ (ver Problema 4(b) del examen de Agosto 2011), o emplear una base de polinomios ortogonales discretos en vez de la base monomial.

ENUNCIADO — PROBLEMA 2

2. Gaussian Quadrature.

(a) Derive the two point Gaussian integration formula $G_2(f)$ for

$I(f) =$

$\int_{-1}^1$

$f(x)dx.$

Indicate for what polynomial degree this rule is exact.

(b) Evaluate the integral using the two-point Gauss Quadrature formula derived:

$\int_{-1}^1$

x^4

dx

$x^2 + 2.$

SOLUCIÓN — PROBLEMA 2

Problema 2 — Cuadratura gaussiana de dos puntos

(a) Derivación de $G_2(f)$ para $I(f) = \int_{-1}^1 f(x) dx$.

Se buscan nodos x_1, x_2 y pesos w_1, w_2 tales que

$$G_2(f) = w_1 f(x_1) + w_2 f(x_2)$$

sea exacta para todo polinomio de grado ≤ 3 (4 parámetros libres $\Rightarrow$ 4 condiciones de exactitud, para $f = 1, x, x^2, x^3$). Por la simetría del intervalo $[-1, 1]$, se busca una solución simétrica $x_1 = -x_2 =: t > 0$, $w_1 = w_2 =: w$.

- $f(x) = 1$: $\int_{-1}^1 1 dx = 2 = w + w = 2w \Rightarrow w = 1$.
- $f(x) = x$: $\int_{-1}^1 x dx = 0 = w(t) + w(-t) = 0$, automáticamente

satisfecha por la simetría.

$$\bullet f(x) = x^2: \int_{-1}^1 x^2 dx = \frac{2}{3} = wt^2 + wt^2 = 2t^2$$

$$\Rightarrow t^2 = \frac{1}{3} \Rightarrow t = \frac{1}{\sqrt{3}}$$

$$\bullet f(x) = x^3: \int_{-1}^1 x^3 dx = 0 = wt^3 + w(-t)^3 = 0, \text{ automáticamente}$$

satisfecha (impar).

Luego

$$G_2(f) = f\left(-\frac{1}{\sqrt{3}}\right) + f\left(\frac{1}{\sqrt{3}}\right),$$

que es **exacta para polinomios de grado ≤ 3** . Esto coincide con la cota general de Gauss: una regla de n nodos es exacta a lo más de grado $2n - 1$, y aquí se alcanza esa cota ($2 \cdot 2 - 1 = 3$) porque los nodos $\pm 1/\sqrt{3}$ son las raíces del polinomio de Legendre $P_2(x) = \frac{1}{2}(3x^2 - 1)$, como exige la teoría general de cuadratura gaussiana.

(b) Evaluación de $\int_1^4 \frac{dx}{x+2}$.

Cambio de variable lineal de $[1, 4]$ a $[-1, 1]$: $x = \frac{3}{2}t + \frac{5}{2}$, $dx = \frac{3}{2} dt$. Entonces

$$\int_1^4 \frac{dx}{x+2} = \int_{-1}^1 \frac{\frac{3}{2} dt}{\frac{3}{2}t + \frac{5}{2} + 2} = \int_{-1}^1 \frac{\frac{3}{2} dt}{\frac{3}{2}(t+3)} = \int_{-1}^1 \frac{dt}{t+3}.$$

Aplicando G_2 con $t = \pm 1/\sqrt{3}$:

$$G_2 = \frac{1}{3 + \frac{1}{\sqrt{3}}} + \frac{1}{3 - \frac{1}{\sqrt{3}}} = \frac{\left(3 - \frac{1}{\sqrt{3}}\right) + \left(3 + \frac{1}{\sqrt{3}}\right)}{9 - \frac{1}{3}} = \frac{6}{26/3} = \frac{18}{26} = \boxed{\frac{9}{13} \approx 0.69231}.$$

Verificación: el valor exacto es $\int_1^4 \frac{dx}{x+2} = \ln(x+2)|_1^4 = \ln 6 - \ln 3 = \ln 2 \approx 0.69315$. La diferencia $|9/13 - \ln 2| \approx 0.0008$ es pequeña y consistente con el error de cuadratura gaussiana $E = \frac{f^{(4)}(\xi)}{135}$ para $n = 2$ (aquí $f(x) = 1/(x+3)$ en $[-1, 1]$ tiene cuarta derivada acotada, dando un error del orden correcto).

ENUNCIADO — PROBLEMA 3

3. Suppose you need to minimize $f(x) = \frac{1}{2} x^T A x + b^T x + c$, $x \in \mathbb{R}^n$, where A is symmetric positive definite.

(a) Let x_0 be the starting point. Perform one step of the steepest descent method with exact line search and find the expression for x_1 .

(b) Prove that the function $f(x)$ is minimized when $Ax = -b$.

(c) Suppose now that you wish to solve $Ax = -b$ using an iterative method. Let x_0 represent the starting point and obtain an expression based on the Jacobi method for the first iterate x_1 .

(d) Compare and contrast in general terms the Jacobi method and the Gauss-Seidel iterative methods.

SOLUCIÓN — PROBLEMA 3

Problema 3 — Minimización de una forma cuadrática: descenso de gradiente y método de Jacobi

Sea $f(x) = \frac{1}{2}x^T Ax - b^T x + c$, $A \in \mathbb{R}^{n \times n}$ simétrica definida positiva (SPD).

(a) Un paso de descenso de gradiente (steepest descent) con búsqueda de línea exacta.

El gradiente es $\nabla f(x) = Ax - b$ (válido porque A es simétrica). La dirección de descenso más pronunciado en x_0 es $-\nabla f(x_0) = b - Ax_0 =: r_0$ (el *residuo*). Se busca $x_1 = x_0 + \alpha_0 r_0$ con α_0 que minimiza $\varphi(\alpha) := f(x_0 + \alpha r_0)$. Derivando:

$$\varphi'(\alpha) = r_0^T A(x_0 + \alpha r_0) - b^T r_0 = r_0^T (Ax_0 - b) + \alpha r_0^T Ar_0 = -r_0^T r_0 + \alpha r_0^T Ar_0.$$

Iguando a cero (y usando $r_0^T Ar_0 > 0$ pues A SPD y $r_0 \neq 0$ en general):

$$\alpha_0 = \frac{r_0^T r_0}{r_0^T Ar_0}.$$

Por lo tanto

$$x_1 = x_0 + \frac{r_0^T r_0}{r_0^T Ar_0} r_0, \quad r_0 = b - Ax_0.$$

(b) f se minimiza cuando $Ax = b$.

Sea $x^* = A^{-1}b$ (existe pues A SPD $\Rightarrow$ invertible). Para cualquier $x \in \mathbb{R}^n$, escribamos $x = x^* + e$. Entonces, usando $Ax^* = b$ y la simetría de A (de modo que $x^{*T} Ae = (Ax^*)^T e = b^T e$):

$$\begin{aligned} f(x^* + e) &= \frac{1}{2}(x^* + e)^T A(x^* + e) - b^T (x^* + e) + c \\ &= \underbrace{\frac{1}{2}x^{*T} Ax^* - b^T x^* + c}_{=f(x^*)} + \underbrace{(x^{*T} Ae - b^T e)}_{=0} + \frac{1}{2}e^T Ae = f(x^*) + \frac{1}{2}e^T Ae. \end{aligned}$$

Como A es SPD, $\frac{1}{2}e^T Ae \geq 0$ con igualdad si y solo si $e = 0$. Luego

$$f(x) = f(x^*) + \frac{1}{2}(x - x^*)^T A(x - x^*) \geq f(x^*) \quad \forall x,$$

con igualdad únicamente en $x = x^* = A^{-1}b$, es decir, exactamente cuando $Ax = b$. Así f tiene un único mínimo global, alcanzado precisamente en la solución del sistema lineal. ■

(c) Primera iterada de Jacobi.

Descomponga $A = D - L - U$ (D diagonal, $-L$ estrictamente triangular inferior, $-U$ estrictamente superior). La iteración de Jacobi es $Dx^{(k+1)} = (L + U)x^{(k)} + b$, es decir

$$x^{(k+1)} = D^{-1}(b - (A - D)x^{(k)}) = x^{(k)} + D^{-1}(b - Ax^{(k)}).$$

Con x_0 el punto inicial y $r_0 = b - Ax_0$:

$$x_1 = x_0 + D^{-1}r_0, \quad D = \text{diag}(a_{11}, \dots, a_{nn}),$$

o, componente a componente,

$$(x_1)_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij}(x_0)_j \right), \quad i = 1, \dots, n.$$

(d) Jacobi vs. Gauss-Seidel.

- **Jacobi:** todas las componentes de $x^{(k+1)}$ se calculan usando *únicamente*

valores de la iterada anterior $x^{(k)}$; las actualizaciones son simultáneas/independientes, lo que hace el método trivialmente paralelizable (cada componente se puede calcular en un procesador distinto) y requiere almacenar dos vectores ($x^{(k)}$ y $x^{(k+1)}$).

- **Gauss-Seidel:** al calcular $(x^{(k+1)})_i$ se usan los valores *ya

actualizados* $(x^{(k+1)})_j$ para $j < i$ y los antiguos $(x^{(k)})_j$ para $j > i$; el método es intrínsecamente secuencial (difícil de paralelizar directamente) pero permite sobrescribir el vector en el mismo arreglo (ahorra memoria) y, para clases amplias de matrices (SPD, diagonalmente dominantes), **converge más rápido** que Jacobi — de hecho, para matrices tridiagonales consistentemente ordenadas se cumple la relación clásica $\rho(B_{GS}) = \rho(B_J)^2$, por lo que Gauss-Seidel requiere aproximadamente la mitad de iteraciones que Jacobi para la misma tolerancia. Ambos son métodos iterativos estacionarios de costo $O(n^2)$ por iteración (o $O(\text{nnz})$ para matrices dispersas), y ambos convergen para todo $x^{(0)}$ si y solo si el radio espectral de su respectiva matriz de iteración es menor que 1 (garantizado, por ejemplo, si A es SPD o estrictamente diagonalmente dominante).

ENUNCIADO — PROBLEMA 4

4. Given a matrix $S = [s_1, \dots, s_N] \in \mathbb{R}^{M \times N}$ of rank $K \leq N$ and $M \leq N$, the proper orthogonal decomposition (POD) is a method to approximate S with $d \ll K$ linearly independent vectors in $\text{span}\{s_j\}_{j=1}^N$.

i.e. Let $S = U \Sigma V^T$ be the singular value decomposition of S , i.e.

$U = [u_1, \dots, u_M] \in \mathbb{R}^{M \times M}$, $V = [v_1, \dots, v_N] \in \mathbb{R}^{N \times N}$,

are orthogonal matrices and $\Sigma =$

[

D

0

]

$\in \mathbb{R}^{M \times N}$, with diagonal matrix $D = \text{diag}(\sigma_1, \dots, \sigma_N)$ containing

the singular values of S :

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_K > \sigma_{K+1} = \dots = \sigma_N = 0$.

1

-- 1 of 2 --

(a) Show that $\text{span}\{s_j\}_{j=1}^N$

$\text{span}\{u_i\}_{i=1}^K$

$\text{span}\{v_i\}_{i=1}^K$.

(b) Let $A_i = u_i v_i^T$

A_i be a rank-1 matrix for $1 \leq i \leq N$. Show the orthogonal decomposition $S =$

$\sum_{i=1}^K$

$\sigma_i A_i$ in the Frobenius inner product

$\langle A, B \rangle_F =$

$\sum_{i=1}^M \sum_{j=1}^N$

$i=1$

$N \sum_{j=1}$

$j=1$

$a_{ij} b_{ij}$,

i.e. show that $\langle A_i, A_j \rangle_F = \delta_{ij}$, where δ_{ij} is the Kronecker delta.

(c) For $d < K$ we may approximate S with $\sum_{i=1}^d$

$\sigma_i A_i$; this is the POD of S . Show the error formula

$\|S -$

$\sum_{i=1}^d$

$i=1$

$\sigma_i A_i\|_F$

$$\frac{1}{2}$$

$$\frac{1}{F}$$

$$=$$

$$K \sum$$

$$i=d+1$$

$$\sigma^2$$

$$i,$$

where $\|\cdot\|_F$ is the norm subordinate to the Frobenius inner product. This expression could be used to find the number d so that the error $\sum_{i=d+1}^K \sigma_i^2$

$$i=d+1 \sigma^2$$

i is within a given tolerance.

SOLUCIÓN — PROBLEMA 4**Problema 4 — Descomposición en valores singulares y POD**

Sea $S = U\Sigma V^T \in \mathbb{R}^{M \times N}$, $\text{rank}(S) = K \leq N \leq M$, con $\sigma_1 \geq \dots \geq \sigma_K > \sigma_{K+1} = \dots = \sigma_N = 0$. Como $\sigma_i = 0$ para $i > K$, la SVD se puede escribir como suma de K términos de rango 1:

$$S = \sum_{i=1}^K \sigma_i u_i v_i^T. \quad (*)$$

(a) $\text{span}\{s_j\}_{j=1}^N = \text{span}\{u_j\}_{j=1}^K.$

($\subseteq$) De (*), la columna j de S es

$$s_j = S e_j = \sum_{i=1}^K \sigma_i u_i (v_i)_j = \sum_{i=1}^K [\sigma_i (v_i)_j] u_i,$$

combinación lineal de $u_1, \dots, u_K$. Luego $s_j \in \text{span}\{u_i\}_{i=1}^K$ para todo j , y $\text{span}\{s_j\}_{j=1}^N \subseteq \text{span}\{u_i\}_{i=1}^K$.

($\supseteq$) Para $i \leq K$, usando que $V^T v_i = e_i$ (columnas de V ortonormales) y que $\Sigma e_i = \sigma_i \hat{e}_i$ (con $\hat{e}_i \in \mathbb{R}^M$ el i -ésimo vector canónico, ya que $\sigma_i \neq 0$):

$$S v_i = U \Sigma V^T v_i = U \Sigma e_i = U(\sigma_i \hat{e}_i) = \sigma_i u_i.$$

Como $\sigma_i \neq 0$ (pues $i \leq K$),

$$u_i = \frac{1}{\sigma_i} S v_i = \frac{1}{\sigma_i} \sum_{j=1}^N (v_i)_j s_j \in \text{span}\{s_j\}_{j=1}^N.$$

Esto vale para todo $i = 1, \dots, K$, así que $\text{span}\{u_i\}_{i=1}^K \subseteq \text{span}\{s_j\}_{j=1}^N$.

Combinando ambas inclusiones: $\text{span}\{s_j\}_{j=1}^N = \text{span}\{u_j\}_{j=1}^K$. ■

(b) Ortogonalidad de $A_i = u_i v_i^T$ en el producto de Frobenius.

Para $1 \leq i, j \leq N$:

$$A_i^T A_j = (u_i v_i^T)^T (u_j v_j^T) = v_i u_i^T u_j v_j^T.$$

Como $u_i^T u_j$ es un escalar, y usando la propiedad cíclica de la traza junto con $\text{tr}(v_i v_j^T) = v_j^T v_i$ (traza de un producto exterior es el producto interior):

$$\langle A_i, A_j \rangle_F = \text{tr}(A_i^T A_j) = \text{tr}(v_i (u_i^T u_j) v_j^T) = (u_i^T u_j) \text{tr}(v_i v_j^T) = (u_i^T u_j)(v_i^T v_j).$$

Como U y V son matrices ortogonales, sus columnas son ortonormales: $u_i^T u_j = \delta_{ij}$ y $v_i^T v_j = \delta_{ij}$. Luego

$$\langle A_i, A_j \rangle_F = \delta_{ij} \cdot \delta_{ij} = \delta_{ij}$$

(pues $\delta_{ij}^2 = \delta_{ij} \in \{0, 1\}$). ■ Esto confirma que $(*)$, $S = \sum_{i=1}^K \sigma_i A_i$, es una descomposición de S en términos **ortonormales** $\{A_i\}$ respecto al producto de Frobenius.

(c) Fórmula del error de la aproximación POD.

Para $d < K$, usando $(*)$:

$$S - \sum_{i=1}^d \sigma_i A_i = \sum_{i=1}^K \sigma_i A_i - \sum_{i=1}^d \sigma_i A_i = \sum_{i=d+1}^K \sigma_i A_i.$$

Por bilinealidad del producto de Frobenius y la ortonormalidad probada en (b):

$$\left\| \sum_{i=d+1}^K \sigma_i A_i \right\|_F^2 = \left\langle \sum_{i=d+1}^K \sigma_i A_i, \sum_{j=d+1}^K \sigma_j A_j \right\rangle_F = \sum_{i=d+1}^K \sum_{j=d+1}^K \sigma_i \sigma_j \underbrace{\langle A_i, A_j \rangle_F}_{=\delta_{ij}} = \sum_{i=d+1}^K \sigma_i^2.$$

Es decir,

$$\left\| S - \sum_{i=1}^d \sigma_i A_i \right\|_F^2 = \sum_{i=d+1}^K \sigma_i^2. \quad \blacksquare$$

Verificación (caso límite $d = K$): la fórmula da error 0, correcto, pues $\sum_{i=1}^K \sigma_i A_i = S$ exactamente. Para $d = 0$ (aproximar por la matriz nula), da $\sum_{i=1}^K \sigma_i^2 = \|S\|_F^2$, lo cual también es consistente (identidad de Parseval para la SVD). Esta fórmula (el teorema de Eckart–Young en su versión de energía) permite elegir el rango d de truncamiento de la POD de modo que $\sum_{i=d+1}^K \sigma_i^2$ esté por debajo de una tolerancia dada.

ENUNCIADO — PROBLEMA 5

5. Consider the two-point boundary value problem

$$Au := (a(x)u')' + c(x)u = f(x) \text{ in } (0, 1), u(0) = u(1) = 0,$$

where $a(x) \geq a_0 > 0$ and $c(x) \geq 0$ are smooth functions in $[0, 1]$, and $f(x) \in L^2(0, 1)$.

(a) Derive the variational form for this problem.

(b) Set $a(x) = 1$ and $c(x) = 0$ and consider a partition of $[0, 1]$

$$0 = x_0 < x_1 < \dots < x_N = 1.$$

Write the system of equations produced by the finite element method with continuous piecewise linear elements $\phi_j(x)$, $j = 1, 2, \dots, N-1$,

$$\phi_j(x) =$$

$$8$$

$$> \quad > \quad <$$

$$> \quad > \quad ;$$

$$xx_{j-1}$$

$$x_j \quad x_{j-1}, \quad x_{j+1} \quad x \quad x_j,$$

$$x_{j+1}x$$

$$x_{j+1}x_j, \quad x_j \quad x \quad x_{j+1},$$

0, otherwise.

(c) Show that this system of equations is equivalent to the one produced by the finite difference method for the uniform partition of f constant.

$$2$$

-- 2 of 2 --

SOLUCIÓN — PROBLEMA 5**Problema 5 — Problema de valores en la frontera: forma variacional y elementos finitos**

$$\mathcal{A}u := -(a(x)u')' + c(x)u = f(x) \quad \text{en } (0, 1), \quad u(0) = u(1) = 0,$$

con $a(x) \geq a_0 > 0$, $c(x) \geq 0$ suaves, $f \in L^2(0, 1)$.

(a) Forma variacional.

Sea v una función de prueba en $H_0^1(0, 1) = \{v \in H^1(0, 1) : v(0) = v(1) = 0\}$. Multiplicando la ecuación por v e integrando en $(0, 1)$:

$$\int_0^1 [-(au')' + cu]v \, dx = \int_0^1 f v \, dx.$$

Integrando por partes el primer término:

$$\int_0^1 -(au')'v \, dx = [-au'v]_0^1 + \int_0^1 au'v' \, dx = \int_0^1 au'v' \, dx,$$

ya que el término de frontera se anula porque $v(0) = v(1) = 0$. Se obtiene la **forma variacional**: hallar $u \in H_0^1(0, 1)$ tal que

$$\mathcal{B}(u, v) := \int_0^1 a(x)u'(x)v'(x) \, dx + \int_0^1 c(x)u(x)v(x) \, dx = \int_0^1 f(x)v(x) \, dx =: F(v) \quad \forall v \in H_0^1(0, 1).$$

($\mathcal{B}$ es bilineal, simétrica, continua y coerciva en $H_0^1(0, 1)$ gracias a $a \geq a_0 > 0$, $c \geq 0$ y la desigualdad de Poincaré, garantizando por Lax-Milgram existencia y unicidad de solución débil.)

(b) Sistema de elementos finitos lineales ($a \equiv 1$, $c \equiv 0$).

Con $a = 1$, $c = 0$: $\mathcal{B}(u, v) = \int_0^1 u'v' \, dx$. Sea $V_h = \text{span}\{\Phi_1, \dots, \Phi_{N-1}\}$ el espacio de elementos finitos lineales continuos con Φ_j las funciones sombrero asociadas a la partición $0 = x_0 < x_1 < \dots < x_N = 1$ (no necesariamente uniforme), $h_j := x_j - x_{j-1}$. Se busca $u_h = \sum_{j=1}^{N-1} U_j \Phi_j$ tal que $\mathcal{B}(u_h, \Phi_i) = F(\Phi_i)$ para $i = 1, \dots, N-1$ (método de Galerkin).

Como $\Phi_j'(x) = 1/h_j$ en (x_{j-1}, x_j) , $\Phi_j'(x) = -1/h_{j+1}$ en (x_j, x_{j+1}) , y 0 fuera de (x_{j-1}, x_{j+1}) , la **matriz de rigidez** $K_{ij} = \int_0^1 \Phi_i' \Phi_j' \, dx$ es tridiagonal con

$$K_{jj} = \frac{1}{h_j} + \frac{1}{h_{j+1}}, \quad K_{j,j-1} = K_{j-1,j} = -\frac{1}{h_j}, \quad K_{ij} = 0 \text{ si } |i - j| \geq 2.$$

El sistema resultante, para $j = 1, \dots, N-1$ (con $U_0 = U_N = 0$), es

$$-\frac{1}{h_j}U_{j-1} + \left(\frac{1}{h_j} + \frac{1}{h_{j+1}}\right)U_j - \frac{1}{h_{j+1}}U_{j+1} = F_j, \quad F_j = \int_0^1 f\Phi_j dx.$$

En particular, para la **partición uniforme** $h_j \equiv h = 1/N$:

$$\frac{-U_{j-1} + 2U_j - U_{j+1}}{h} = F_j = \int_0^1 f\Phi_j dx, \quad j = 1, \dots, N-1.$$

(c) Equivalencia con diferencias finitas para $f \equiv \text{constante}$ (malla uniforme).

El esquema de diferencias finitas centradas estándar para $-u'' = f$ (con f constante) en la malla uniforme es

$$\frac{-U_{j-1} + 2U_j - U_{j+1}}{h^2} = f, \quad j = 1, \dots, N-1, \quad U_0 = U_N = 0. \quad (\text{FD})$$

Del lado de elementos finitos, cuando f es constante:

$$F_j = \int_0^1 f\Phi_j dx = f \int_{x_{j-1}}^{x_{j+1}} \Phi_j dx = f \left(\frac{1}{2}h \cdot 1 + \frac{1}{2}h \cdot 1 \right) = fh,$$

pues $\int \Phi_j dx$ es el área bajo el "sombrero" triangular: dos triángulos de base h y altura 1, área total h . Sustituyendo en la ecuación de FEM del inciso (b):

$$\frac{-U_{j-1} + 2U_j - U_{j+1}}{h} = fh \iff \frac{-U_{j-1} + 2U_j - U_{j+1}}{h^2} = f,$$

que es exactamente (FD), con las mismas condiciones de frontera $U_0 = U_N = 0$. Como ambos son el **mismo** sistema lineal tridiagonal, tienen la misma (única) solución $\{U_j\}$: el método de elementos finitos con elementos lineales reproduce exactamente el esquema de diferencias finitas centradas de segundo orden cuando f es constante y la malla es uniforme. ■

Verificación: si además $c = 0$ y se usa la fórmula de cuadratura del trapecio compuesta (exacta para f lineal/constante) para aproximar F_j en el caso general, se recupera la misma equivalencia; esta es la razón estructural por la que, para coeficientes y fuente suaves, FEM lineal y diferencias finitas centradas dan resultados muy cercanos en mallas uniformes.