

ENUNCIADO DEL EXAMEN

Math 685: Preliminary Exam – Spring 2014

January 15

Instructions: This is a closed book, closed notes in class exam. You are required to do any four out of

ve problems but are strongly encouraged to attempt all ve of them.

1. Suppose you have a large set of data (x_j, f_j) , $j = 0, 1, \dots, n$, available at equidistant points $x_j = j$

n on

the interval $[0, 1]$. Suppose you want to approximate these data with a polynomial of degree k where

$1 \ll k \ll n$.

(a) Formulate a least squares problem for the polynomial t of the form $Ay = b$. Explain how you will

de ne the entries of the matrix A and the vector b .

(b) Derive a formula for the solution of the least squares problem.

2. Gaussian Quadrature.

(a) Derive the two point Gaussian integration formula $G_2(f)$ for

$I(f) =$

$\int_1$

1

$f(x)dx$.

Indicate for what polynomial degree this rule is exact.

(b) Evaluate the integral using the two-point Gauss Quadrature fourmula derived:

$$\int_4^1$$

$$1$$

$$dx$$

$$x + 2.$$

3. Suppose you need to minimize $f(x) = \frac{1}{2} x^T A x + b^T x + c$, $x \in \mathbb{R}^n$, where A is symmetric positive definite.

(a) Let x_0 be the starting point. Perform one step of the steepest descent method with exact line search and find the expression for x_1 .

(b) Prove that the function $f(x)$ is minimized when $Ax = -b$.

(c) Suppose now that you wish to solve $Ax = b$ using an iterative method. Let x_0 represent the starting point and obtain an expression based on the Jacobi method for the first iterate x_1 .

(d) Compare and contrast in general terms the Jacobi method and the Gauss-Seidel iterative methods.

4. Given a matrix $S = [s_1, \dots, s_N] \in \mathbb{R}^{M \times N}$ of rank $K \leq \min\{M, N\}$ and M, N , the proper orthogonal decomposition (POD) is a method to approximate S with $d \ll K$ linearly independent vectors in

span $\{s_1, \dots, s_N\}$. Let $S = U \Sigma V^T$ be the singular value decomposition of S , i.e.

$U = [u_1, \dots, u_M] \in \mathbb{R}^{M \times M}$, $V = [v_1, \dots, v_N] \in \mathbb{R}^{N \times N}$,

are orthogonal matrices and $\Sigma =$

$\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_K & & \\ & & & 0 & \end{bmatrix}$

$\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_K & & \\ & & & 0 & \end{bmatrix}$

$\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_K & & \\ & & & 0 & \end{bmatrix}$

$\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_K & & \\ & & & 0 & \end{bmatrix}$

]

$2 \text{ RM} \begin{bmatrix} \text{STE} \\ \text{N} \end{bmatrix}$, with diagonal matrix $D = \text{diag}(\sigma_1, \dots, \sigma_N)$ containing

the singular values of S :

$$\sigma_1 \begin{bmatrix} \text{NAK} \\ \text{SOH} \\ \text{SOH} \\ \text{SOH} \\ \text{NAK} \end{bmatrix} \sigma_K > \sigma_{K+1} = \begin{bmatrix} \text{SOH} \\ \text{SOH} \\ \text{SOH} \end{bmatrix} = \sigma_N = 0.$$

1

(a) Show that $\text{spanfsj } g_N$

$$j=1 = \text{spanfuj } g_K$$

$$j=1.$$

(b) Let $A_i = u_i v_i^T$

i be a rank-1 matrix for $1 \leq i \leq N$. Show the orthogonal decomposition $S =$

$$\sum_K$$

$i=1 \sigma_i A_i$ in the Frobenius inner product

$$\langle A, B \rangle_F =$$

$$M \sum$$

$$i=1$$

$$N \sum$$

$$j=1$$

$$a_{ij} b_{ij},$$

i.e. show that $\langle A_i, A_j \rangle_F = \delta_{ij}$, where δ_{ij} is the Kronecker delta.

(c) For $d < K$ we may approximate S with $\sum_d$

$i=1 \sigma_i A_i$; this is the POD of S . Show the error formula

S

$d \sum$

$i=1$

$\sigma_i A_i$

2

F

=

$K \sum$

$i=d+1$

σ^2

$i,$

where $\| \cdot \|_F$ is the norm subordinate to the Frobenius inner product. This expression could be

used to find the number d so that the error $\sum_{i=d+1}^K$

$\sum_{i=d+1}^K \sigma_i^2$

is within a given tolerance.

5. Consider the two-point boundary value problem

$Au := (a(x)u')' + c(x)u = f(x)$ in $(0, 1)$, $u(0) = u(1) = 0$,

where $a(x) \geq a_0 > 0$ and $c(x) \geq 0$ are smooth functions in $[0, 1]$, and $f(x) \in L^2(0, 1)$.

(a) Derive the variational form for this problem.

(b) Set $a(x) = 1$ and $c(x) = 0$ and consider a partition of $[0, 1]$

$0 = x_0 < x_1 < \dots < x_N = 1$.

Write the system of equations produced by the finite element method with continuous piecewise

linear elements $\phi_j(x)$, $j = 1, 2, \dots, N-1$,

$$\phi_j(x) =$$

8

$$x_j > x_{j-1} > x_{j+1}$$

$$x_j > x_{j-1} > x_{j+1} :$$

$$x_{j+1} - x_j$$

$$x_j - x_{j-1}, x_{j+1} - x_j,$$

$$x_{j+1} - x_j$$

$$x_{j+1} - x_j, x_{j+1} - x_j,$$

0, otherwise.

(c) Show that this system of equations is equivalent to the one produced by the finite difference method

for the uniform partition of f constant.

2

SOLUCIÓN DETALLADA

Solución — GMU Numerical Analysis Preliminary Exam, Enero 2014

Formato: resolver 4 de 5 problemas, libro/notas cerrados.

Sección principal del temario: examen con fuerte énfasis en **álgebra lineal numérica** — mínimos cuadrados (Problema 1), descenso de gradiente y el método de Jacobi para sistemas lineales (Problema 3), y la descomposición en valores singulares / POD (Problema 4) — junto con los temas adicionales de cuadratura gaussiana (Problema 2) y elementos finitos para un problema de valores en la frontera (Problema 5).

Problema 1 — Ajuste polinomial por mínimos cuadrados

(a) Formulación del problema $(Ay=b)$.

Se tienen $(n+1)$ datos $((x_j, f_j))$, $(j=0, \dots, n)$, con $(x_j = j/n \in [0, 1])$, y se busca el polinomio de grado $(k \ll n)$ $[p(x) = \sum_{i=0}^k y_i x^i]$ que mejor aproxima los datos en el sentido de mínimos cuadrados. Como hay $(n+1)$ condiciones $(p(x_j) \approx f_j)$ y solo $(k+1)$ incógnitas $(y_0, \dots, y_k)$ (con $(k+1 \leq n+1)$, en general $(k+1 < n+1)$), el sistema $[p(x_j) = \sum_{i=0}^k y_i x_j^i = f_j, \quad j=0, \dots, n]$ está **sobredeterminado**. En forma matricial $(Ay=b)$ con $[A = \text{big}(a_{ji}) \in \mathbb{R}^{(n+1) \times (k+1)}, \quad a_{ji} = x_j^i \quad (j=0, \dots, n, i=0, \dots, k), \quad b = (f_0, f_1, \dots, f_n)^T \in \mathbb{R}^{n+1}]$ (A) es una matriz tipo Vandermonde rectangular (alta y delgada, pues $(k+1 \ll n+1)$). Se busca $(y \in \mathbb{R}^{k+1})$ que minimice $(\|Ay-b\|_2^2)$, pues en general el sistema no tiene solución exacta.

(b) Solución del problema de mínimos cuadrados.

Rango completo de (A) . Si $(Ay=0)$ con $(y \neq 0)$, entonces el polinomio $(q(x) = \sum_{i=0}^k y_i x^i)$ (de grado $(\leq k)$, no idénticamente nulo) se anularía en los $(n+1)$ puntos distintos $(x_0, \dots, x_n)$. Pero un polinomio no nulo de grado $(\leq k)$ tiene a lo más (k) raíces, y $(n+1 > k)$ (pues $(k \ll n)$). Contradicción. Luego (A) tiene rango columna completo $(k+1)$, y $(A^T A \in \mathbb{R}^{(k+1) \times (k+1)})$ es invertible (de hecho SPD).

Ecuaciones normales. Sea $\phi(y) = \|Ay-b\|_2^2 = (Ay-b)^T (Ay-b) = y^T A^T A y - 2y^T A^T b + b^T b$. Como ϕ es cuadrática convexa (su Hessiano es $(2A^T A \succ 0)$), su mínimo se alcanza donde el gradiente se anula: $(\nabla_y \phi(y) = 2A^T A y - 2A^T b = 0 \quad \Longleftrightarrow \quad A^T A y = A^T b)$. Por la invertibilidad de $(A^T A)$: $\boxed{y = (A^T A)^{-1} A^T b}$.

Verificación dimensional: $(A^T \in \mathbb{R}^{(k+1) \times (n+1)})$, así $(A^T A \in \mathbb{R}^{(k+1) \times (k+1)})$ y $(A^T b \in \mathbb{R}^{k+1})$: la fórmula produce

efectivamente un vector $(y \in \mathbb{R}^{k+1})$, como se requiere.

Nota numérica. En la práctica, para (k) moderado, resolver $(A^T A y = A^T b)$ directamente puede estar mal condicionado $(\kappa(A^T A) = \kappa(A)^2)$; es preferible usar la factorización $(A = QR)$ (Householder o Gram-Schmidt) y resolver el sistema triangular $(R_1 y = Q_1^T b)$ (ver Problema 4(b) del examen de Agosto 2011), o emplear una base de polinomios ortogonales discretos en vez de la base monomial.

Problema 2 — Cuadratura gaussiana de dos puntos

(a) Derivación de $(G_2(f))$ para $(I(f) = \int_{-1}^1 f(x) dx)$.

Se buscan nodos (x_1, x_2) y pesos (w_1, w_2) tales que $[G_2(f) = w_1 f(x_1) + w_2 f(x_2)]$ sea exacta para todo polinomio de grado (≤ 3) (4 parámetros libres $(\Rightarrow)$ 4 condiciones de exactitud, para $(f=1, x, x^2, x^3)$). Por la simetría del intervalo $([-1, 1])$, se busca una solución simétrica $(x_1 = -x_2 =: t > 0)$, $(w_1 = w_2 =: w)$.

- $(f(x)=1)$: $\int_{-1}^1 1 dx = 2 = w + w = 2w \Rightarrow w = 1$
- $(f(x)=x)$: $\int_{-1}^1 x dx = 0 = w(t) + w(-t) = 0$, automáticamente

satisfecha por la simetría.

- $(f(x)=x^2)$: $\int_{-1}^1 x^2 dx = \frac{2}{3} = wt^2 + wt^2 = 2t^2$

$\Rightarrow t^2 = \frac{1}{3} \Rightarrow t = \frac{1}{\sqrt{3}}$

- $(f(x)=x^3)$: $\int_{-1}^1 x^3 dx = 0 = wt^3 + w(-t)^3 = 0$, automáticamente

satisfecha (impar).

Luego $G_2(f) = f\left(-\frac{1}{\sqrt{3}}\right) + f\left(\frac{1}{\sqrt{3}}\right)$ que es **exacta para polinomios de grado (≤ 3)** . Esto coincide con la cota general de Gauss: una regla de (n) nodos es exacta a lo más de grado $(2n-1)$, y aquí se alcanza esa cota $(2 \cdot 2 - 1 = 3)$ porque los nodos $(\pm 1/\sqrt{3})$ son las raíces del polinomio de Legendre $(P_2(x) = \frac{1}{2}(3x^2 - 1))$, como exige la teoría general de cuadratura gaussiana.

(b) Evaluación de $(\int_{-1}^1 \frac{dx}{x+2})$.

Cambio de variable lineal de $([1, 4])$ a $([-1, 1])$: $(x = \frac{3}{2}t + \frac{5}{2})$, $(dx = \frac{3}{2}dt)$. Entonces $\int_{-1}^1 \frac{dx}{x+2} = \int_{-1}^1 \frac{\frac{3}{2}dt}{\frac{3}{2}t + \frac{5}{2}} = \int_{-1}^1 \frac{dt}{t+3}$. Aplicando (G_2) con $(t = \pm 1/\sqrt{3})$: $G_2 = \frac{1}{3} + \frac{1}{3\sqrt{3}} + \frac{1}{3} - \frac{1}{3\sqrt{3}} = \frac{2}{3}$ $(\left(3 - \frac{1}{\sqrt{3}}\right) + \left(3 + \frac{1}{\sqrt{3}}\right)) \Rightarrow \frac{9 - \frac{1}{3}}{26} = \frac{6}{26} = \frac{3}{13}$ $\Rightarrow \boxed{\frac{9}{13} \approx 0.69231}$

Verificación: el valor exacto es $\left(\int_1^4 \frac{dx}{x+2}\right) = \ln(x+2)\big|_1^4 = \ln 6 - \ln 3 = \ln 2 \approx 0.69315$. La diferencia $(9/13 - \ln 2) \approx 0.0008$ es pequeña y consistente con el error de cuadratura gaussiana $(E = \frac{f^{(4)}(\xi)}{135})$ para $(n=2)$ (aquí $(f(x)=1/(x+3))$ en $([-1,1])$ tiene cuarta derivada acotada, dando un error del orden correcto).

Problema 3 — Minimización de una forma cuadrática: descenso de gradiente y método de Jacobi

Sea $(f(x) = \frac{1}{2}x^T A x - b^T x + c)$, $(A \in \mathbb{R}^{n \times n})$ simétrica definida positiva (SPD).

(a) Un paso de descenso de gradiente (steepest descent) con búsqueda de línea exacta.

El gradiente es $(\nabla f(x) = Ax - b)$ (válido porque (A) es simétrica). La dirección de descenso más pronunciado en (x_0) es $(-\nabla f(x_0) = b - Ax_0 =: r_0)$ (el *residuo*). Se busca $(x_1 = x_0 + \alpha r_0)$ con (α_0) que minimiza $(\varphi(\alpha) = f(x_0 + \alpha r_0))$. Derivando: $(\varphi'(\alpha) = r_0^T A(x_0 + \alpha r_0) - b^T r_0 = r_0^T (Ax_0 - b) + \alpha r_0^T A r_0 = -r_0^T r_0 + \alpha r_0^T A r_0)$. Igualando a cero (y usando $(r_0^T A r_0 > 0)$ pues (A) SPD y $(r_0 \neq 0)$ en general): $(\alpha_0 = \frac{r_0^T r_0}{r_0^T A r_0})$. Por lo tanto $(\boxed{x_1 = x_0 + \frac{r_0^T r_0}{r_0^T A r_0} r_0, r_0 \Leftrightarrow r_0 = b - Ax_0})$

(b) (f) se minimiza cuando $(Ax=b)$.

Sea $(x^* = A^{-1}b)$ (existe pues (A) SPD $(\Rightarrow)$ invertible). Para cualquier $(x \in \mathbb{R}^n)$, escribamos $(x = x^* + e)$. Entonces, usando $(Ax^* = b)$ y la simetría de (A) (de modo que $(x^*{}^T A e = (Ax^*)^T e = b^T e)$): $(f(x^* + e) = \frac{1}{2}(x^* + e)^T A (x^* + e) - b^T (x^* + e) + c = \underbrace{\frac{1}{2} x^*{}^T A x^* - b^T x^* + c}_{=f(x^*)} + \underbrace{\frac{1}{2} e^T A e - b^T e}_{=0} = f(x^*) + \frac{1}{2} e^T A e)$. Como (A) es SPD, $(\frac{1}{2} e^T A e \geq 0)$ con igualdad si y solo si $(e=0)$. Luego $(f(x) = f(x^*) + \frac{1}{2}(x - x^*)^T A (x - x^*)) \geq f(x^*) \Leftrightarrow \forall x, (x = x^* = A^{-1}b)$, es decir, exactamente cuando $(Ax=b)$. Así (f) tiene un único mínimo global, alcanzado precisamente en la solución del sistema lineal. $(\blacksquare)$

(c) Primera iterada de Jacobi.

Descomponga $(A = D - L - U)$ ((D) diagonal, $(-L)$ estrictamente triangular inferior, $(-U)$ estrictamente superior). La iteración de Jacobi es $(Dx^{(k+1)} = (L + U)x^{(k)} + b)$, es decir $(x^{(k+1)} = D^{-1}(b - (L + U)x^{(k)}) = x^{(k)} + D^{-1}(b - Ax^{(k)})$. Con (x_0) el punto inicial y $(r_0 = b - Ax_0)$: $(\boxed{x_1 = x_0 + D^{-1}r_0, \text{ donde } D = \text{diag}(a_{11}, \dots, a_{nn})})$ o, componente a componente, $(x_1)_i = \frac{1}{a_{ii}}(b_i - \sum_{j \neq i} a_{ij}(x_0)_j)$, $(i=1, \dots, n)$

(d) Jacobi vs. Gauss-Seidel.

- **Jacobi:** todas las componentes de $(x^{(k+1)})_i$ se calculan usando *únicamente*

valores de la iterada anterior $(x^{(k)})_i$; las actualizaciones son simultáneas/independientes, lo que hace el método trivialmente paralelizable (cada componente se puede calcular en un procesador distinto) y requiere almacenar dos vectores $(x^{(k)})$ y $(x^{(k+1)})$.

- **Gauss-Seidel:** al calcular $(x^{(k+1)})_i$ se usan los valores $(x^{(k+1)})_j$ para $j < i$; ya

actualizados $(x^{(k+1)})_j$ para $j < i$; el método es intrínsecamente secuencial (difícil de paralelizar directamente) pero permite sobrescribir el vector en el mismo arreglo (ahorra memoria) y, para clases amplias de matrices (SPD, diagonalmente dominantes), **converge más rápido** que Jacobi — de hecho, para matrices tridiagonales consistentemente ordenadas se cumple la relación clásica $\rho(B_{GS}) = \rho(B_J)^2$, por lo que Gauss-Seidel requiere aproximadamente la mitad de iteraciones que Jacobi para la misma tolerancia. Ambos son métodos iterativos estacionarios de costo $O(n^2)$ por iteración (o $O(\text{nnz})$ para matrices dispersas), y ambos convergen para todo $(x^{(0)})$ si y solo si el radio espectral de su respectiva matriz de iteración es menor que 1 (garantizado, por ejemplo, si A es SPD o estrictamente diagonalmente dominante).

Problema 4 — Descomposición en valores singulares y POD

Sea $(S = U \Sigma V^T \in \mathbb{R}^{M \times N})$, $\text{rank}(S) = K \leq N \leq M$, con $(\sigma_1 \geq \dots \geq \sigma_K > \sigma_{K+1} = \dots = \sigma_N = 0)$. Como $(\sigma_i = 0)$ para $(i > K)$, la SVD se puede escribir como suma de (K) términos de rango 1: $S = \sum_{i=1}^K \sigma_i u_i v_i^T$.

(a) $\text{span}\{s_j\}_{j=1}^N = \text{span}\{u_j\}_{j=1}^K$.

(\subseteq) De (s_j) , la columna (j) de (S) es $s_j = \sum_{i=1}^K \sigma_i u_i v_{ij}$ combinación lineal de $(u_1, \dots, u_K)$. Luego $(s_j \in \text{span}\{u_i\}_{i=1}^K)$ para todo (j) , y $\text{span}\{s_j\}_{j=1}^N \subseteq \text{span}\{u_i\}_{i=1}^K$.

(\supseteq) Para $(i \leq K)$, usando que $(V^T v_i = e_i)$ (columnas de (V) ortonormales) y que $(\Sigma e_i = \sigma_i \hat{e}_i)$ (con $(\hat{e}_i \in \mathbb{R}^M)$ el (i) -ésimo vector canónico, ya que $(\sigma_i \neq 0)$): $(S v_i = U \Sigma V^T v_i = U \Sigma e_i = U(\sigma_i \hat{e}_i) = \sigma_i u_i)$. Como $(\sigma_i \neq 0)$ (pues $(i \leq K)$), $(u_i = \frac{1}{\sigma_i} S v_i)$. Esto vale para todo $(i = 1, \dots, K)$, así que $\text{span}\{u_i\}_{i=1}^K \subseteq \text{span}\{s_j\}_{j=1}^N$.

Combinando ambas inclusiones: $\text{span}\{s_j\}_{j=1}^N = \text{span}\{u_j\}_{j=1}^K$. $\square$

(b) Ortogonalidad de $(A_i = u_i v_i^T)$ en el producto de Frobenius.

Para $(1 \leq i, j \leq N)$: $[A_i^T A_j] = (u_i^T u_j) = v_i^T v_j$. Como $(u_i^T u_j)$ es un escalar, y usando la propiedad cíclica de la traza junto con $(\text{tr}(v_i^T v_j) = v_j^T v_i)$ (traza de un producto exterior es el producto interior): $(A_i^T A_j) = \text{tr}(v_i (u_i^T u_j) v_j^T) = (u_i^T u_j) \text{tr}(v_i^T v_j)$. Como (U) y (V) son matrices ortogonales, sus columnas son ortonormales: $(u_i^T u_j) = \delta_{ij}$ y $(v_i^T v_j) = \delta_{ij}$. Luego $(A_i^T A_j) = \delta_{ij}$ (pues $(\delta_{ij})^2 = \delta_{ij} \in \{0, 1\}$). $\blacksquare$ Esto confirma que $(S = \sum_{i=1}^K \sigma_i A_i)$, es una descomposición de (S) en términos **ortonormales** $(\{A_i\})$ respecto al producto de Frobenius.

(c) Fórmula del error de la aproximación POD.

Para $(d$

Verificación (caso límite $(d=K)$): la fórmula da error (0) , correcto, pues $(\sum_{i=1}^K \sigma_i A_i = S)$ exactamente. Para $(d=0)$ (aproximar por la matriz nula), da $(\sum_{i=1}^K \sigma_i^2 = \|S\|_F^2)$, lo cual también es consistente (identidad de Parseval para la SVD). Esta fórmula (el teorema de Eckart–Young en su versión de energía) permite elegir el rango (d) de truncamiento de la POD de modo que $(\sum_{i=d+1}^K \sigma_i^2)$ esté por debajo de una tolerancia dada.

Problema 5 — Problema de valores en la frontera: forma variacional y elementos finitos

$\mathcal{A}u := -(a(x)u)' + c(x)u = f(x)$ en $(0, 1)$, $u(0) = u(1) = 0$, con $(a(x) \geq a_0 > 0)$, $(c(x) \geq 0)$ suaves, $(f \in L^2(0, 1))$.

(a) Forma variacional.

Sea (v) una función de prueba en $(H_0^1(0, 1) = \{v \in H^1(0, 1): v(0) = v(1) = 0\})$. Multiplicando la ecuación por (v) e integrando en $((0, 1))$: $\int_0^1 [-(au)' + cu]v \, dx = \int_0^1 f v \, dx$. Integrando por partes el primer término: $\int_0^1 -(au)'v \, dx = \int_0^1 -au'v \, dx + \int_0^1 au'v \, dx = \int_0^1 au'v \, dx$, ya que el término de frontera se anula porque $(v(0) = v(1) = 0)$. Se obtiene la **forma variacional**: hallar $(u \in H_0^1(0, 1))$ tal que $(\boxed{\mathcal{B}}(u, v) := \int_0^1 a(x)u'(x)v'(x) \, dx + \int_0^1 c(x)u(x)v(x) \, dx = \int_0^1 f(x)v(x) \, dx =: F(v) \quad \forall v \in H_0^1(0, 1).)$ $(\mathcal{B})$ es bilineal, simétrica, continua y coerciva en $(H_0^1(0, 1))$ gracias a $(a \geq a_0 > 0)$, $(c \geq 0)$ y la desigualdad de Poincaré, garantizando por Lax-Milgram existencia y unicidad de solución débil.)

(b) Sistema de elementos finitos lineales $(a \equiv 1)$, $(c \equiv 0)$.

Con $(a=1, c=0)$: $(\mathcal{B})(u, v) = \int_0^1 u'v' dx$). Sea $(V_h = \text{span}\{\Phi_1, \dots, \Phi_{N-1}\})$ el espacio de elementos finitos lineales continuos con (Φ_j) las funciones sombrero asociadas a la partición $(0=x_0$

Como $(\Phi_j'(x) = 1/h_j)$ en $((x_{j-1}, x_j))$, $(\Phi_j'(x) = -1/h_{j+1})$ en $((x_j, x_{j+1}))$, y (0) fuera de $((x_{j-1}, x_{j+1}))$, la **matriz de rigidez** $(K_{ij} = \int_0^1 \Phi_i' \Phi_j' dx)$ es tridiagonal con $(K_{jj} = \frac{1}{h_j} + \frac{1}{h_{j+1}})$, $K_{j,j-1} = K_{j-1,j} = -\frac{1}{h_j}$, $K_{ij} = 0$ $|i-j| \geq 2$. El sistema resultante, para $(j=1, \dots, N-1)$ (con $(U_0 = U_N = 0)$), es $(-\frac{1}{h_j} U_{j-1} + (\frac{1}{h_j} + \frac{1}{h_{j+1}}) U_j - \frac{1}{h_{j+1}} U_{j+1}) = F_j$, $F_j = \int_0^1 f \Phi_j dx$. En particular, para la **partición uniforme** $(h_j \equiv h = 1/N)$: $(-\frac{1}{h} U_{j-1} + 2 U_j - \frac{1}{h} U_{j+1}) = F_j = \int_0^1 f \Phi_j dx$, $j=1, \dots, N-1$.

(c) Equivalencia con diferencias finitas para $(f \equiv \text{constante})$ (malla uniforme).

El esquema de diferencias finitas centradas estándar para $(-u'' = f)$ (con (f) constante) en la malla uniforme es $(\frac{-U_{j-1} + 2U_j - U_{j+1}}{h^2} = f)$, $j=1, \dots, N-1$, $U_0 = U_N = 0$. $\tag{FD}$

Del lado de elementos finitos, cuando (f) es constante: $(F_j = \int_0^1 f \Phi_j dx = f \int_{x_{j-1}}^{x_{j+1}} \Phi_j dx = f \left(\frac{1}{2} h + \frac{1}{2} h \right) = fh)$ pues $(\int \Phi_j dx)$ es el área bajo el "sombrero" triangular: dos triángulos de base (h) y altura (1) , área total (h) . Sustituyendo en la ecuación de FEM del inciso (b): $(\frac{-U_{j-1} + 2U_j - U_{j+1}}{h} = fh)$ $\Longleftrightarrow \frac{-U_{j-1} + 2U_j - U_{j+1}}{h^2} = f$, que es exactamente (FD), con las mismas condiciones de frontera $(U_0 = U_N = 0)$. Como ambos son el **mismo** sistema lineal tridiagonal, tienen la misma (única) solución $(\{U_j\})$: el método de elementos finitos con elementos lineales reproduce exactamente el esquema de diferencias finitas centradas de segundo orden cuando (f) es constante y la malla es uniforme. $\blacksquare$

Verificación: si además $(c=0)$ y se usa la fórmula de cuadratura del trapecio compuesta (exacta para (f) lineal/constante) para aproximar (F_j) en el caso general, se recupera la misma equivalencia; esta es la razón estructural por la que, para coeficientes y fuente suaves, FEM lineal y diferencias finitas centradas dan resultados muy cercanos en mallas uniformes.