

ENUNCIADO DEL EXAMEN

Numerical Analysis. Preliminary Exam January 2016.

Closed book. Closed notes. No phones or calculators.

Solve any 5 problems. Circle the numbers of 5 problems to be graded.

1 2 3 4 5 6 7

1. Which method of solving a linear system of equations quicker in general for large systems: LU factorization or Gauss-Jordan elimination? Justify your answer by calculation the dominant terms in the arithmetic operations count for both methods.

2. Let $\mathbf{b} \in \mathbb{R}^n$ be given and $\mathbf{A} \in \mathbb{R}^{n \times n}$ be a strictly diagonally dominant matrix, namely,

$$\max_{1 \leq i \leq n} \sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} = r < 1.$$

- (a) Show that the *Jacobi* iteration $\mathbf{x}_{k+1} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}_k + \mathbf{D}^{-1}\mathbf{b}$ converges regardless of the initial guess $\mathbf{x}_0 \in \mathbb{R}^n$.

- (b) Show that the *Gauss-Seidel* iteration $\mathbf{x}_{k+1} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}\mathbf{x}_k + (\mathbf{D} - \mathbf{L})^{-1}\mathbf{b}$ converges regardless of the initial guess $\mathbf{x}_0 \in \mathbb{R}^n$.

3. Suppose that a function g maps the interval $[a, b]$ into itself and g satisfies a Lipschitz condition with a Lipschitz constant $0 \leq \lambda < 1$, then

- (a) Show that the sequence $x_{n+1} = g(x_n)$, $n = 0, 1, \dots$ (for any initial approximation $x_0 \in [a, b]$) converges to a unique fixed point ξ in $[a, b]$.

- (b) Moreover, prove the following error bound involved in using the sequence x_n to approximate ξ given by:

$$|x_n - \xi| \leq \frac{\lambda^n}{1 - \lambda} |x_1 - x_0| \quad \forall n \geq 1.$$

4. Prove that any local minimum of a convex function f on a convex set $S \subseteq \mathbb{R}^n$ is a global minimum of f on S .

5. If the integrand f is a twice continuously differentiable convex function on $[a, b]$, show that the composite midpoint and and trapezoid quadrature rules satisfy the following properties for any $k = 1, 2, \dots$:

$$M_k(f) \leq \int_a^b f(x) dx \leq T_k(f).$$

6. Consider the initial-value problem $y'(t) = f(t, y)$ for $0 \leq t \leq 1$ with $y(0) = a$. Consider the one-step method

$$y_{k+1} = y_k + h \Phi(t_k, y_k, h)$$

with $y_0 = a$, $h = 1/N$, and $t_k = kh$ for $k = 0, 1, \dots, N$. Assume that there is a constant L such that $|\Phi(t, y, h) - \Phi(t, z, h)| \leq L |y - z|$ for all $t, y, z \in \mathcal{R}$. Furthermore, assume that the solution $y(t)$ satisfies $|y(t+h) - y(t) - h\Phi(t, y(t), h)| \leq c h^{p+1}$ for all $t, h \in [0, 1]$. Prove that

$$|y_N - y(1)| \leq c \frac{h^p}{L} (e^L - 1).$$

7. Consider the two-point boundary value problem with parameter $b \in \mathbb{R}$:

$$-u'' + bu' + u = 2x \quad \text{in } (0, 1), \quad \text{with } u(0) = u(1) = 0. \quad (1)$$

- (a) Write the finite difference approximation of (1) using *centered* differences and *upwind* differences on a uniform mesh with meshsize h . Write the matrix of the system and examine how the equations would change if $u(1) = \alpha \neq 0$.
- (b) Set up the finite element approximation for this problem, based on piecewise linear elements in equidistant points. State the convergence rate in an appropriate norm.

SOLUCIÓN DETALLADA

Solución — GMU Numerical Analysis Preliminary Exam, Enero 2016

Formato: resolver 5 de 7 problemas, libro/notas cerrados, sin teléfonos ni calculadora.

Sección principal del temario: examen mixto/compreensivo. Cubre álgebra lineal numérica (conteo de operaciones LU vs. Gauss-Jordan, convergencia de Jacobi y Gauss-Seidel bajo dominancia diagonal), ecuaciones no lineales (teorema del punto fijo de Banach), y los temas adicionales de optimización convexa, cuadratura (desigualdad punto medio/trapezio para integrandos convexos), EDO de valor inicial (cota de error de un método de un paso general) y BVP (diferencias finitas centradas/upwind y elementos finitos).

Problema 1 — LU vs. Gauss-Jordan: conteo de operaciones

Afirmación: para sistemas grandes, la factorización LU (eliminación gaussiana seguida de sustitución) es más rápida que la eliminación de Gauss-Jordan.

Conteo para LU + sustitución. En el paso $k = 1, \dots, n-1$ de la eliminación, para cada fila $i = k+1, \dots, n$ se calcula el multiplicador $m_{ik} = a_{ik}/a_{kk}$ (una división) y se actualizan las $n-k$ entradas restantes de esa fila, $a_{ij} \leftarrow a_{ij} - m_{ik}a_{kj}$ para $j = k+1, \dots, n$ (una multiplicación y una resta cada una). Por paso k hay $(n-k)$ filas a actualizar, así que:

$$\text{divisiones por paso } k : n-k, \quad \text{mult./restas por paso } k : (n-k)^2.$$

Sumando sobre $k = 1, \dots, n-1$ (con $\sum_{m=1}^{n-1} m = \frac{n(n-1)}{2}$ y $\sum_{m=1}^{n-1} m^2 = \frac{(n-1)n(2n-1)}{6}$):

$$\# \text{divisiones} = \frac{n(n-1)}{2} = O(n^2), \quad \# \text{mult.} = \# \text{restas} = \frac{(n-1)n(2n-1)}{6} \approx \frac{n^3}{3}.$$

Total de flops (mult+add) de la fase de eliminación: $\frac{2n^3}{3} + O(n^2)$. La sustitución hacia atrás cuesta $O(n^2)$, término subdominante. Luego:

$$\boxed{\text{Costo}(LU) = \frac{2}{3}n^3 + O(n^2)}.$$

Conteo para Gauss-Jordan. Aquí, en cada paso $k = 1, \dots, n$ se elimina la variable k de **todas** las demás $n-1$ filas (no solo las de abajo), actualizando en cada una las $(n+1-k)$ entradas restantes (incluyendo la columna del lado derecho aumentado):

$$\text{mult./restas por paso } k : (n-1)(n+1-k).$$

Sumando sobre $k = 1, \dots, n$ (con $\sum_{m=1}^n m = \frac{n(n+1)}{2}$):

$$\# \text{mult.} = \# \text{restas} = (n-1) \sum_{k=1}^n (n+1-k) = (n-1) \frac{n(n+1)}{2} \approx \frac{n^3}{2}.$$

Total de flops: $\frac{n^3}{2} + \frac{n^3}{2} = n^3 + O(n^2)$:

$$\boxed{\text{Costo}(\text{Gauss-Jordan}) = n^3 + O(n^2).}$$

Comparación. El término dominante de LU es $\frac{2}{3}n^3$ y el de Gauss-Jordan es n^3 . Como $\frac{2}{3}n^3 < n^3$ para todo n , y la razón asintótica es $n^3 / (\frac{2}{3}n^3) = \frac{3}{2}$, **Gauss-Jordan requiere aproximadamente 50% más operaciones aritméticas que LU para n grande. Además, con LU ya factorizado, resolver para un nuevo lado derecho b cuesta solo $O(n^2)$ (sustitución hacia adelante/atrás), mientras que Gauss-Jordan tendría que rehacer la eliminación completa ($O(n^3)$) salvo que se guarde A^{-1} explícitamente (lo cual de por sí cuesta $\approx n^3$, más que LU). **Conclusión: LU (eliminación gaussiana + sustitución) es la opción más eficiente. ** ■

Problema 2 — Convergencia de Jacobi y Gauss-Seidel bajo dominancia diagonal por filas

Sea $A = D - L - U$ (descomposición estándar: D diagonal, $-L$ estrictamente triangular inferior, $-U$ estrictamente triangular superior, ambas con las entradas correspondientes de A , es decir $L_{ij} = -a_{ij}$ para $j < i$ y $U_{ij} = -a_{ij}$ para $j > i$), con A estrictamente diagonalmente dominante por filas: $\max_i \frac{1}{|a_{ii}|} \sum_{j \neq i} |a_{ij}| = r < 1$.

(a) Jacobi

La matriz de iteración es $B_J = D^{-1}(L + U)$, con entradas $(B_J)_{ij} = -a_{ij}/a_{ii}$ ($j \neq i$), $(B_J)_{ii} = 0$. Su norma inducida ∞ (norma máxima de suma de filas) es exactamente

$$\|B_J\|_{\infty} = \max_i \sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} = r < 1.$$

Sea x^* el punto fijo ($x^* = B_J x^* + D^{-1}b$) y $e^{(k)} = x^{(k)} - x^*$. Restando la ecuación de iteración de la de punto fijo: $e^{(k+1)} = B_J e^{(k)}$, así que $e^{(k)} = B_J^k e^{(0)}$. Tomando norma ∞ y usando la submultiplicatividad de la norma inducida:

$$\|e^{(k)}\|_{\infty} = \|B_J^k e^{(0)}\|_{\infty} \leq \|B_J\|_{\infty}^k \|e^{(0)}\|_{\infty} = r^k \|e^{(0)}\|_{\infty}.$$

Como $0 \leq r < 1$, se tiene $r^k \rightarrow 0$, luego $\|e^{(k)}\|_{\infty} \rightarrow 0$ para **cualquier** $x^{(0)} \in \mathbb{R}^n$ (es decir, cualquier $e^{(0)}$). Por lo tanto $x^{(k)} \rightarrow x^*$ independientemente de la aproximación inicial. ■

(b) Gauss-Seidel

La matriz de iteración es $B_{GS} = (D - L)^{-1}U$, definida por $(D - L)x^{(k+1)} = Ux^{(k)} + b$. Sea λ un valor propio de B_{GS} con vector propio $v \neq 0$; normalizamos $\|v\|_\infty = 1$ y sea p un índice con $|v_p| = 1$. De $B_{GS}v = \lambda v$ se sigue $Uv = \lambda(D - L)v$, es decir

$$\lambda Dv = \lambda Lv + Uv.$$

En componentes (usando $L_{ij} = -a_{ij}$ para $j < i$, $U_{ij} = -a_{ij}$ para $j > i$), la fila $i = p$ da:

$$\lambda a_{pp}v_p = -\lambda \sum_{j < p} a_{pj}v_j - \sum_{j > p} a_{pj}v_j \iff \lambda \left(a_{pp}v_p + \sum_{j < p} a_{pj}v_j \right) = - \sum_{j > p} a_{pj}v_j.$$

Tomando módulo y usando $|v_p| = 1$, $|v_j| \leq 1$ para todo j :

$$|\lambda| \left(|a_{pp}| - \sum_{j < p} |a_{pj}| \right) \leq |\lambda| \left| a_{pp}v_p + \sum_{j < p} a_{pj}v_j \right| = \left| \sum_{j > p} a_{pj}v_j \right| \leq \sum_{j > p} |a_{pj}|.$$

Sean $S_1 = \sum_{j < p} |a_{pj}|$, $S_2 = \sum_{j > p} |a_{pj}|$. Por dominancia diagonal estricta de la fila p : $S_1 + S_2 < |a_{pp}|$, en particular $|a_{pp}| - S_1 \geq S_2 + (|a_{pp}| - S_1 - S_2) > S_1 \geq 0$, así que el denominador es positivo y

$$|\lambda| \leq \frac{S_2}{|a_{pp}| - S_1}.$$

Como $S_1 + S_2 < |a_{pp}|$, se sigue $S_2 < |a_{pp}| - S_1$, luego el cociente de la derecha es **estrictamente menor que 1**. Por lo tanto $|\lambda| < 1$ para **todo** valor propio λ de B_{GS} , es decir $\rho(B_{GS}) < 1$.

Como en (a), $e^{(k)} = x^{(k)} - x^*$ satisface $e^{(k+1)} = B_{GS}e^{(k)}$, y $\rho(B_{GS}) < 1$ implica $B_{GS}^k \rightarrow 0$ (hecho estándar de matrices: $\rho(B) < 1 \iff B^k \rightarrow 0$), luego $e^{(k)} \rightarrow 0$ para todo $e^{(0)}$. Por lo tanto Gauss-Seidel converge para cualquier $x^{(0)} \in \mathbb{R}^n$. ■

Problema 3 — Teorema del punto fijo de Banach en $[a, b]$

$g : [a, b] \rightarrow [a, b]$ con $|g(x) - g(y)| \leq \lambda|x - y|$, $0 \leq \lambda < 1$.

(a) Existencia, unicidad y convergencia

Cota telescópica. Para $n \geq 1$: $|x_{n+1} - x_n| = |g(x_n) - g(x_{n-1})| \leq \lambda |x_n - x_{n-1}|$, por inducción $|x_{n+1} - x_n| \leq \lambda^n |x_1 - x_0|$.

Cauchy. Para $m > n$, por la desigualdad triangular y la suma geométrica:

$$|x_m - x_n| \leq \sum_{k=n}^{m-1} |x_{k+1} - x_k| \leq |x_1 - x_0| \sum_{k=n}^{m-1} \lambda^k \leq |x_1 - x_0| \lambda^n \sum_{j=0}^{\infty} \lambda^j = \frac{\lambda^n}{1 - \lambda} |x_1 - x_0|,$$

que tiende a 0 cuando $n \rightarrow \infty$ (pues $0 \leq \lambda < 1$). Luego (x_n) es de Cauchy en $[a, b] \subset \mathbb{R}$, que es completo (cerrado y acotado), así que $x_n \rightarrow \xi$ para algún $\xi \in [a, b]$ (el límite queda en $[a, b]$ por ser este cerrado).

ξ es punto fijo. g es Lipschitz, luego continua; tomando límite en $x_{n+1} = g(x_n)$: $\xi = g(\xi)$.

Unicidad. Si ξ_1, ξ_2 son puntos fijos, $|\xi_1 - \xi_2| = |g(\xi_1) - g(\xi_2)| \leq \lambda |\xi_1 - \xi_2| \Rightarrow (1 - \lambda) |\xi_1 - \xi_2| \leq 0$. Como $\lambda < 1$, $|\xi_1 - \xi_2| = 0$, es decir $\xi_1 = \xi_2$. ■

(b) Cota de error

De la desigualdad de Cauchy de la parte (a), fijando n y dejando $m \rightarrow \infty$ (con $x_m \rightarrow \xi$ y continuidad de $|\cdot|$):

$$|x_n - \xi| = \lim_{m \rightarrow \infty} |x_n - x_m| \leq \frac{\lambda^n}{1 - \lambda} |x_1 - x_0|, \quad \forall n \geq 1. \quad \blacksquare$$

Problema 4 — Mínimo local de una función convexa es mínimo global

Sea f convexa en el conjunto convexo $S \subseteq \mathbb{R}^n$: para todo $x, y \in S$, $\theta \in [0, 1]$, $f((1 - \theta)x + \theta y) \leq (1 - \theta)f(x) + \theta f(y)$.

Sea $x^* \in S$ un mínimo local: existe $\epsilon > 0$ tal que $f(x^*) \leq f(z)$ para todo $z \in S \cap B(x^*, \epsilon)$.

Demostración. Sea $y \in S$ arbitrario, $y \neq x^*$. Para $\theta \in (0, 1]$ defina $z_\theta = (1 - \theta)x^* + \theta y$. Como S es convexo, $z_\theta \in S$ para todo $\theta \in [0, 1]$. Además $\|z_\theta - x^*\| = \theta \|y - x^*\| \rightarrow 0$ cuando $\theta \rightarrow 0^+$, así que existe $\theta_0 > 0$ (por ejemplo $\theta_0 = \min\{1, \epsilon/\|y - x^*\|\}$) tal que $z_\theta \in B(x^*, \epsilon)$ para todo $0 < \theta \leq \theta_0$. Fijemos tal $\theta \in (0, \theta_0]$.

Por minimalidad local: $f(x^*) \leq f(z_\theta)$.

Por convexidad: $f(z_\theta) = f((1 - \theta)x^* + \theta y) \leq (1 - \theta)f(x^*) + \theta f(y)$.

Combinando:

$$f(x^*) \leq (1 - \theta)f(x^*) + \theta f(y) \implies \theta f(x^*) \leq \theta f(y) \implies f(x^*) \leq f(y)$$

(dividiendo por $\theta > 0$). Como $y \in S$ era arbitrario, x^* es mínimo global de f en S . ■

Problema 5 — Desigualdad $M_k(f) \leq \int_a^b f \leq T_k(f)$ para f convexa

Basta probarlo en cada subintervalo $[x_i, x_{i+1}]$ de ancho h y sumar sobre los k subintervalos de la partición uniforme (las reglas compuestas son sumas de las reglas simples).

****Dos hechos de convexidad (con $f \in C^2$, aunque solo se usa diferenciabilidad):****

Hecho 1 (la gráfica queda por debajo de la cuerda). Para $x = (1 - \theta)x_i + \theta x_{i+1} \in [x_i, x_{i+1}]$ (con $\theta = (x - x_i)/h$), la definición de convexidad da directamente

$$f(x) \leq (1 - \theta)f(x_i) + \theta f(x_{i+1}) =: \ell(x)$$

donde ℓ es la recta secante que une $(x_i, f(x_i))$ y $(x_{i+1}, f(x_{i+1}))$.

Hecho 2 (la gráfica queda por encima de la tangente). Sea c cualquier punto y x arbitrario. Para $t \in (0, 1]$, convexidad da $f(c + t(x - c)) \leq (1 - t)f(c) + tf(x)$, es decir

$$\frac{f(c + t(x - c)) - f(c)}{t} \leq f(x) - f(c).$$

Tomando $t \rightarrow 0^+$, el lado izquierdo tiende a $f'(c)(x - c)$ (definición de derivada direccional/regla de la cadena), luego

$$f(x) \geq f(c) + f'(c)(x - c) \quad \forall x.$$

Trapecio ($f \leq T_k$). Integrando la desigualdad del Hecho 1 sobre $[x_i, x_{i+1}]$:

$$\int_{x_i}^{x_{i+1}} f(x) dx \leq \int_{x_i}^{x_{i+1}} \ell(x) dx = \frac{h}{2} (f(x_i) + f(x_{i+1})),$$

pues $\int \ell$ es exactamente el área del trapecio bajo la secante. Sumando sobre todos los subintervalos: $\int_a^b f \leq T_k(f)$.

Punto medio ($M_k \leq f$). Sea $c = \frac{x_i + x_{i+1}}{2}$ el punto medio. Aplicando el Hecho 2 con este c e integrando sobre $[x_i, x_{i+1}]$:

$$\int_{x_i}^{x_{i+1}} f(x) dx \geq \int_{x_i}^{x_{i+1}} [f(c) + f'(c)(x - c)] dx = hf(c) + f'(c) \underbrace{\int_{x_i}^{x_{i+1}} (x - c) dx}_{=0 \text{ (simetría respecto a } c)} = hf(c).$$

El término lineal se anula porque $x - c$ es una función impar respecto al punto medio c del intervalo de integración. Sumando sobre todos los subintervalos: $M_k(f) \leq \int_a^b f$.

Combinando ambas desigualdades:

$$\boxed{M_k(f) \leq \int_a^b f(x) dx \leq T_k(f).} \blacksquare$$

Verificación: con $f(x) = x^2$ (convexa, $f'' = 2 \geq 0$) en $[0, 2]$, $k = 1$: $M_1 = 2 \cdot f(1) = 2$, $T_1 = \frac{2}{2}(f(0) + f(2)) = 4$, e $\int_0^2 x^2 dx = 8/3 \approx 2.67$. En efecto $2 \leq 8/3 \leq 4$. ✓

Problema 6 — Cota de error global de un método de un paso general

Método: $y_{k+1} = y_k + h\Phi(t_k, y_k, h)$, $y_0 = a$, $h = 1/N$, $t_k = kh$. Hipótesis: Lipschitz en Φ respecto a y con constante L , y error de truncamiento local $|y(t+h) - y(t) - h\Phi(t, y(t), h)| \leq ch^{p+1}$.

Demostración. Sea $e_k = y_k - y(t_k)$ el error global, $e_0 = 0$. Definiendo el error de truncamiento local $\tau_k = y(t_{k+1}) - y(t_k) - h\Phi(t_k, y(t_k), h)$ (con $|\tau_k| \leq ch^{p+1}$), restamos:

$$e_{k+1} = y_{k+1} - y(t_{k+1}) = [y_k + h\Phi(t_k, y_k, h)] - [y(t_k) + h\Phi(t_k, y(t_k), h) + \tau_k] = e_k + h[\Phi(t_k, y_k, h) - \Phi(t_k, y(t_k), h)] - \tau_k.$$

Tomando módulo y usando la condición de Lipschitz y $|\tau_k| \leq ch^{p+1}$:

$$|e_{k+1}| \leq |e_k| + hL|e_k| + |\tau_k| \leq (1 + hL)|e_k| + ch^{p+1}.$$

Afirmación (inducción): $|e_k| \leq \frac{ch^p}{L} [(1 + hL)^k - 1]$ para todo $k \geq 0$.

Base $k = 0$: $e_0 = 0$, y el lado derecho es 0. ✓

Paso inductivo: suponiendo la cota para k ,

$$\begin{aligned} |e_{k+1}| &\leq (1 + hL)|e_k| + ch^{p+1} \leq (1 + hL)\frac{ch^p}{L} [(1 + hL)^k - 1] + ch^{p+1} \\ &= \frac{ch^p}{L}(1 + hL)^{k+1} - \frac{ch^p}{L}(1 + hL) + ch^{p+1} = \frac{ch^p}{L}(1 + hL)^{k+1} - \frac{ch^p}{L} - ch^{p+1} + ch^{p+1} = \frac{ch^p}{L} [(1 + hL)^{k+1} - 1]. \end{aligned}$$

Esto completa la inducción.

Conclusión. En $k = N$, con $Nh = 1$: usando $1 + x \leq e^x$ para todo $x \in \mathbb{R}$, $(1 + hL)^N \leq e^{hLN} = e^L$. Por lo tanto:

$$|y_N - y(1)| = |e_N| \leq \frac{ch^p}{L} [(1 + hL)^N - 1] \leq \frac{ch^p}{L} (e^L - 1). \blacksquare$$

Verificación de dimensiones/límite: si $c \rightarrow 0$ (método exacto), la cota tiende a 0, consistente. Si $h \rightarrow 0$ con $p \geq 1$, la cota $\rightarrow 0$: convergencia.

Problema 7 — BVP con advección: $-u'' + bu' + u = 2x$, $u(0) = u(1) = 0$

Malla uniforme $x_i = ih$, $i = 0, \dots, N$, $h = 1/N$, incógnitas $u_1, \dots, u_{N-1}$ ($u_0 = 0$, $u_N = 0$).

(a) Diferencias finitas centradas y upwind

Centradas: $u''(x_i) \approx \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}$, $u'(x_i) \approx \frac{u_{i+1} - u_{i-1}}{2h}$. Sustituyendo en la ecuación y multiplicando por h^2 :

$$-u_{i-1} + 2u_i - u_{i+1} + \frac{bh}{2}(u_{i+1} - u_{i-1}) + h^2u_i = 2h^2x_i$$

$$\left(-1 - \frac{bh}{2}\right)u_{i-1} + (2 + h^2)u_i + \left(-1 + \frac{bh}{2}\right)u_{i+1} = 2h^2x_i, \quad i = 1, \dots, N-1.$$

Matriz tridiagonal $(N-1) \times (N-1)$:

$$A_{\text{cent}} = \begin{pmatrix} 2 + h^2 & -\left(1 - \frac{bh}{2}\right) & & & \\ -\left(1 + \frac{bh}{2}\right) & 2 + h^2 & -\left(1 - \frac{bh}{2}\right) & & \\ & \ddots & \ddots & \ddots & \\ & & -\left(1 + \frac{bh}{2}\right) & 2 + h^2 & \end{pmatrix}.$$

Esta matriz es diagonalmente dominante (fila i : $|2 + h^2|$ vs. $|1 + \frac{bh}{2}| + |1 - \frac{bh}{2}|$) solo si $|bh/2| < 1$, es decir $h < 2/|b|$; si el número de Péclet de malla $|b|h/2$ excede 1, aparecen oscilaciones espurias (no físicas) en la solución discreta — el defecto clásico de la advección centrada en el régimen dominado por convección.

Upwind (caso $b > 0$, análogo para $b < 0$ con diferencia hacia adelante): se reemplaza $u'(x_i) \approx \frac{u_i - u_{i-1}}{h}$ (diferencia hacia atrás, "aguas arriba" respecto al signo de b). La ecuación queda

$$\begin{aligned} -u_{i-1} + 2u_i - u_{i+1} + bh(u_i - u_{i-1}) + h^2u_i &= 2h^2x_i \\ -(1 + bh)u_{i-1} + (2 + bh + h^2)u_i - u_{i+1} &= 2h^2x_i. \end{aligned}$$

Ahora, para **todo** $h > 0$ (con $b > 0$): $|-(1 + bh)| + |-1| = 2 + bh < 2 + bh + h^2$ (diagonal), es decir la matriz es ****estrictamente diagonalmente dominante sin restricción sobre h ****. El precio es que la aproximación de u' pasa de segundo orden ($O(h^2)$, centrada) a primer orden ($O(h)$, upwind): se introduce "difusión numérica/artificial" que estabiliza el esquema a costa de precisión — el intercambio clásico estabilidad-vs-exactitud en esquemas de advección-difusión.

Condición de frontera $u(1) = \alpha \neq 0$: el operador (la matriz A) no cambia; solo se modifica la última ecuación ($i = N-1$), pues ahora $u_N = \alpha$ es un dato conocido en vez de 0. El término conocido pasa al lado derecho: para el esquema centrado, $b_{N-1} = 2h^2x_{N-1} + \left(1 - \frac{bh}{2}\right)\alpha$; para el esquema upwind, $b_{N-1} = 2h^2x_{N-1} + \alpha$ (pues el coeficiente de u_N en esa fila es -1).

(b) Elementos finitos lineales por partes

Forma débil: multiplicando por $v \in H_0^1(0, 1)$ e integrando por partes ($v(0) = v(1) = 0$ anula el término de frontera):

$$\int_0^1 u'v' dx + b \int_0^1 u'v dx + \int_0^1 uv dx = \int_0^1 2xv dx, \quad \forall v \in H_0^1(0, 1).$$

Sea $V_h = \text{span}\{\phi_1, \dots, \phi_{N-1}\}$ con ϕ_i las funciones sombrero estándar ($\phi_i(x_j) = \delta_{ij}$) en la malla uniforme. El problema de Galerkin: hallar $u_h = \sum_j c_j \phi_j \in V_h$ tal que para $i = 1, \dots, N-1$:

$$\sum_j c_j \left[\int_0^1 \phi_j' \phi_i' dx + b \int_0^1 \phi_j' \phi_i dx + \int_0^1 \phi_j \phi_i dx \right] = \int_0^1 2x \phi_i dx.$$

Esto produce el sistema $Kc = F$ con:

- **Matriz de rigidez** $\int \phi_i' \phi_j'$: tridiagonal $\frac{1}{h}(2, -1)$ (el

laplaciano discreto estándar de elementos P_1).

- **Término de advección** $b \int \phi_j' \phi_i$: matriz antisimétrica que, con

cuadratura exacta e interpolación lineal, reproduce exactamente el término centrado $\pm b/2$ del inciso (a): la formulación de Galerkin estándar con P_1 es, en este problema 1-D con malla uniforme, algebraicamente equivalente al esquema de diferencias centradas — y por tanto hereda el mismo defecto de oscilaciones para $|b|h/2 > 1$ (a menos que se estabilice, p. ej. con SUPG/difusión de línea de corriente).

- **Matriz de masa** $\int \phi_i \phi_j$: tridiagonal consistente

$\frac{h}{6}(4, 1)$ (diagonal $2h/3$, fuera de diagonal $h/6$).

Tasa de convergencia: por el Lema de Céa y la teoría de interpolación de elementos P_1 (asumiendo $u \in H^2(0, 1)$ y h suficientemente pequeño para la coercividad de la forma bilineal):

$$\|u - u_h\|_{H^1(0,1)} = O(h), \quad \|u - u_h\|_{L^2(0,1)} = O(h^2)$$

(esta última, de orden óptimo, vía el truco de dualidad de Aubin-Nitsche). Estas son las tasas óptimas para elementos lineales: primer orden en energía (H^1), segundo orden en L^2 .