

ENUNCIADO DEL EXAMEN

Numerical Analysis. Preliminary Exam January 2016.

Closed book. Closed notes. No phones or calculators.

Solve any 5 problems. Circle the numbers of 5 problems to be graded.

1 2 3 4 5 6 7

1. Which method of solving a linear system of equations quicker in general for large systems: LU factorization or Gauss-Jordan elimination? Justify your answer by calculation the dominant terms in the arithmetic operations count for both methods.

2. Let $b \in \mathbb{R}^n$ be given and $A \in \mathbb{R}^{n \times n}$ be a strictly diagonally dominant matrix, namely,

$\max$

$1 \leq i \leq n$

$\sum$

$j \neq i$

$|$

$|a_{ij}|$

$|$

$|$

$|a_{ii}| = r < 1.$

(a) Show that the Jacobi iteration $x_{k+1} = D^{-1} (L + U) x_k + D^{-1}b$ converges regardless of the initial guess $x_0 \in \mathbb{R}^n$.

(b) Show that the Gauss-Seidel iteration $x_{k+1} = (D - L)^{-1} Ux_k + (D - L)^{-1} b$ converges regardless of the initial guess $x_0 \in \mathbb{R}^n$.

3. Suppose that a function g maps the interval $[a, b]$ into itself and g satisfies a Lipschitz condition with

a Lipschitz constant $0 \leq \lambda < 1$, then

(a) Show that the sequence $x_{n+1} = g(x_n)$, $n = 0, 1, \dots$ (for any initial approximation $x_0 \in [a, b]$)

converges to a unique fixed point ξ in $[a, b]$.

(b) Moreover, prove the following error bound involved in using the sequence x_n to approximate ξ given by:

$$|x_n - \xi| \leq \lambda^n$$

$$1 - \lambda |x_1 - x_0| \forall n \geq 1.$$

4. Prove that any local minimum of a convex function f on a convex set $S \subseteq \mathbb{R}^n$ is a global minimum of

f on S .

5. If the integrand f is a twice continuously differentiable convex function on $[a, b]$, show that the composite

midpoint and trapezoid quadrature rules satisfy the following properties for any $k = 1, 2, \dots$:

$$M_k(f) \leq$$

$$\int_a^b$$

$$a$$

$$f(x)dx \leq T_k(f).$$

6. Consider the initial-value problem $y'(t) = f(t, y)$ for $0 \leq t \leq 1$ with $y(0) = a$. Consider the one-step method

$$y_{k+1} = y_k + h \Phi(t_k, y_k, h)$$

1

with $y_0 = a$, $h = 1/N$, and $t_k = kh$ for $k = 0, 1, \dots, N$. Assume that there is a constant L such that $|\Phi(t, y, h) - \Phi(t, z, h)| \leq L |y - z|$ for all $t, y, z \in \mathbb{R}$. Furthermore, assume that the solution $y(t)$ satisfies $|y(t + h) - y(t) - h\Phi(t, y(t), h)| \leq c h^{p+1}$ for all $t, h \in [0, 1]$. Prove that

$$|y_N - y(1)| \leq c h^p$$

$$L (e^L - 1).$$

7. Consider the two-point boundary value problem with parameter $b \in \mathbb{R}$:

$$-u'' + bu' + u = 2x \text{ in } (0, 1), \text{ with } u(0) = u(1) = 0. \quad (1)$$

(a) Write the finite difference approximation of (1) using centered differences and upwind differences on a uniform mesh with meshsize h . Write the matrix of the system and examine how the equations would change if $u(1) = \alpha \neq 0$.

(b) Set up the finite element approximation for this problem, based on piecewise linear elements in equidistant points. State the convergence rate in an appropriate norm.

2

SOLUCIÓN DETALLADA

Solución — GMU Numerical Analysis Preliminary Exam, Enero 2016

Formato: resolver 5 de 7 problemas, libro/notas cerrados, sin teléfonos ni calculadora.

Sección principal del temario: examen mixto/compreensivo. Cubre álgebra lineal numérica (conteo de operaciones LU vs. Gauss-Jordan, convergencia de Jacobi y Gauss-Seidel bajo dominancia diagonal), ecuaciones no lineales (teorema del punto fijo de Banach), y los temas adicionales de optimización convexa, cuadratura (desigualdad punto medio/trapecio para integrandos convexos), EDO de valor inicial (cota de error de un método de un paso general) y BVP (diferencias finitas centradas/upwind y elementos finitos).

Problema 1 — LU vs. Gauss-Jordan: conteo de operaciones

Afirmación: para sistemas grandes, la factorización (LU) (eliminación gaussiana seguida de sustitución) es más rápida que la eliminación de Gauss-Jordan.

Conteo para (LU) + sustitución. En el paso $(k=1, \dots, n-1)$ de la eliminación, para cada fila $(i=k+1, \dots, n)$ se calcula el multiplicador $(m_{ik} = a_{ik}/a_{kk})$ (una división) y se actualizan las $(n-k)$ entradas restantes de esa fila, $(a_{ij} \leftarrow a_{ij} - m_{ik}a_{kj})$ para $(j=k+1, \dots, n)$ (una multiplicación y una resta cada una). Por paso (k) hay $((n-k))$ filas a actualizar, así que:

$$\{\text{divisiones por paso } k: n-k, \text{ mult./restas por paso } k: (n-k)^2.\}$$

Sumando sobre $(k=1, \dots, n-1)$ (con $(\sum_{m=1}^{n-1} m = \frac{n(n-1)}{2})$ y $(\sum_{m=1}^{n-1} m^2 = \frac{(n-1)n(2n-1)}{6})$):

$$\{\#\text{divisiones} = \frac{n(n-1)}{2} = O(n^2), \text{ mult./restas} = \frac{(n-1)n(2n-1)}{6} \approx \frac{n^3}{3}.\}$$

Total de flops (mult+add) de la fase de eliminación: $(\frac{2n^3}{3} + O(n^2))$. La sustitución hacia atrás cuesta $(O(n^2))$, término subdominante. Luego:

$$\boxed{\text{Costo}(LU) = \frac{2}{3}n^3 + O(n^2).}$$

Conteo para Gauss-Jordan. Aquí, en cada paso $(k=1, \dots, n)$ se elimina la variable (k) de **todas** las demás $(n-1)$ filas (no solo las de abajo), actualizando en cada una las $((n+1-k))$ entradas restantes (incluyendo la columna del lado derecho aumentado):

$$\{\text{mult./restas por paso } k: (n-1)(n+1-k).\}$$

Sumando sobre $(k=1, \dots, n)$ (con $(\sum_{m=1}^n m = \frac{n(n+1)}{2})$):

$$\text{mult.} = \text{restas} = (n-1) \sum_{k=1}^n (n+1-k) = (n-1) \frac{n(n+1)}{2} \approx \frac{n^3}{2}.$$

Total de flops: $\frac{n^3}{2} + \frac{n^3}{2} = n^3 + O(n^2)$:

$$\boxed{\text{Costo(Gauss-Jordan)} = n^3 + O(n^2).}$$

Comparación. El término dominante de (LU) es $\frac{2}{3}n^3$ y el de Gauss-Jordan es n^3 . Como $\frac{2}{3}n^3 < n^3$ para todo n , y la razón asintótica es $\frac{n^3}{\frac{2}{3}n^3} = \frac{3}{2}$, **Gauss-Jordan** requiere aproximadamente 50% más operaciones aritméticas que (LU) para n grande. Además, con (LU) ya factorizado, resolver para un nuevo lado derecho b cuesta solo $O(n^2)$ (sustitución hacia adelante/atrás), mientras que Gauss-Jordan tendría que rehacer la eliminación completa ($O(n^3)$) salvo que se guarde A^{-1} explícitamente (lo cual de por sí cuesta $\approx n^3$), más que (LU) . **Conclusión:** (LU) (eliminación gaussiana + sustitución) es la opción más eficiente. $\square$

Problema 2 — Convergencia de Jacobi y Gauss-Seidel bajo dominancia diagonal por filas

Sea $A = D - L - U$ (descomposición estándar: D diagonal, $-L$ estrictamente triangular inferior, $-U$ estrictamente triangular superior, ambas con las entradas correspondientes de A), es decir $(L_{ij} = -a_{ij})$ para $(j < i)$, con A estrictamente diagonalmente dominante por filas: $\frac{1}{\max_i |a_{ii}|} \sum_{j \neq i} |a_{ij}| = r < 1$.

(a) Jacobi

La matriz de iteración es $(B_J = D^{-1}(L + U))$, con entradas $((B_J)_{ij} = -a_{ij}/a_{ii})$ ($(j \neq i)$), $((B_J)_{ii} = 0)$. Su norma inducida (∞) (norma máxima de suma de filas) es exactamente

$$\|B_J\|_{\infty} = \max_i \sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} = r < 1.$$

Sea x^* el punto fijo $(x^* = B_J x^* + D^{-1}b)$ y $(e^{(k)} = x^{(k)} - x^*)$. Restando la ecuación de iteración de la de punto fijo: $(e^{(k+1)} = B_J e^{(k)})$, así que $(e^{(k)} = B_J^k e^{(0)})$. Tomando norma (∞) y usando la submultiplicatividad de la norma inducida:

$$\begin{aligned} \|e^{(k)}\|_{\infty} &= \|B_J^k e^{(0)}\|_{\infty} \\ \|B_J\|_{\infty}^k \|e^{(0)}\|_{\infty} &= r^k \|e^{(0)}\|_{\infty} \end{aligned}$$

Como $(0 \leq r < 1)$, se tiene $(r^k \rightarrow 0)$, luego $(\|e^{(k)}\|_{\infty} \rightarrow 0)$ para **cualquier** $(x^{(0)} \in \mathbb{R}^n)$ (es decir, cualquier $(e^{(0)})$). Por lo tanto $(x^{(k)} \rightarrow x^*)$ independientemente de la aproximación inicial. $\square$

(b) Gauss-Seidel

La matriz de iteración es $(B_{GS}) = (D-L)^{-1}U$, definida por $((D-L)x^{(k+1)} = Ux^{(k)} + b)$. Sea (λ) un valor propio de (B_{GS}) con vector propio $(v \neq 0)$; normalizamos $(\|v\|_\infty = 1)$ y sea (p) un índice con $(|v_p| = 1)$. De $(B_{GS}v = \lambda v)$ se sigue $(Uv = \lambda(D-L)v)$, es decir

$$(\lambda D - U)v = \lambda L v$$

En componentes (usando $(L_{ij} = -a_{ij})$ para $(j \neq i)$), la fila $(i=p)$ da:

$$(\lambda a_{pp} v_p = -\lambda \sum_{j \neq p} a_{pj} v_j) \quad \Longleftrightarrow \quad \lambda \Big(a_{pp} v_p + \sum_{j \neq p} a_{pj} v_j\Big)$$

Tomando módulo y usando $(|v_p| = 1)$, $(|v_j| \leq 1)$ para todo (j) :

$$|\lambda| \Big(|a_{pp}| + \sum_{j \neq p} |a_{pj}| \Big) \leq \sum_{j \neq p} |a_{pj}|$$

Sean $(S_1 = \sum_{j \neq p} |a_{pj}|)$. Por dominancia diagonal estricta de la fila (p) : $(S_1 + S_2 < |a_{pp}|)$, en particular $(|a_{pp}| - S_1 \geq S_2 + (|a_{pp}| - S_1 - S_2) > S_1 \geq 0)$, así que el denominador es positivo y

$$|\lambda| \leq \frac{S_2}{|a_{pp}| - S_1}$$

Como $(S_1 + S_2 < |a_{pp}|)$, se sigue $(S_2 < |a_{pp}| - S_1)$, luego el cociente de la derecha es **estrictamente menor que 1**. Por lo tanto $(|\lambda| < 1)$ para **todo** valor propio (λ) de (B_{GS}) , es decir $(\rho(B_{GS}) < 1)$.

Como en (a), $(e^{(k)} = x^{(k)} - x^*)$ satisface $(e^{(k+1)} = B_{GS} e^{(k)})$, y $(\rho(B_{GS}) < 1)$ implica $(B_{GS}^k \rightarrow 0)$ (hecho estándar de matrices: $(\rho(B) < 1 \iff B^k \rightarrow 0)$), luego $(e^{(k)} \rightarrow 0)$ para todo $(e^{(0)})$. Por lo tanto Gauss-Seidel converge para cualquier $(x^{(0)} \in \mathbb{R}^n)$. $\square$

Problema 3 — Teorema del punto fijo de Banach en $([a, b])$

$(g: [a, b] \rightarrow [a, b])$ con $(|g(x) - g(y)| \leq \lambda |x - y|)$, $(0 \leq \lambda < 1)$.

(a) Existencia, unicidad y convergencia

Cota telescópica. Para $(n \geq 1)$: $|x_{n+1} - x_n| = |g(x_n) - g(x_{n-1})| \leq \lambda |x_n - x_{n-1}|$, y por inducción $|x_{n+1} - x_n| \leq \lambda^n |x_1 - x_0|$.

Cauchy. Para $(m > n)$, por la desigualdad triangular y la suma geométrica:

$$|x_m - x_n| \leq \sum_{k=n}^{m-1} |x_{k+1} - x_k| \leq |x_1 - x_0| \sum_{k=n}^{m-1} \lambda^k \leq |x_1 - x_0| \lambda^n \sum_{j=0}^{\infty} \lambda^j = \frac{\lambda^n}{1 - \lambda} |x_1 - x_0|$$

que tiende a (0) cuando $(n \rightarrow \infty)$ (pues $(0 \leq \lambda < 1)$). Luego (x_n) es de Cauchy en $([a, b] \subset \mathbb{R})$, que es completo (cerrado y acotado), así que $(x_n \rightarrow x)$ para algún (x) .

$(x_i \in [a, b])$ (el límite queda en $[a, b]$) por ser este cerrado).

(x_i) es punto fijo. g es Lipschitz, luego continua; tomando límite en $(x_{n+1} = g(x_n))$: $(x_i = g(x_i))$.

Unicidad. Si (x_1, x_2) son puntos fijos, $|x_1 - x_2| = |g(x_1) - g(x_2)| \leq \lambda |x_1 - x_2| \Rightarrow (1 - \lambda) |x_1 - x_2| \leq 0$. Como $\lambda < 1$, $|x_1 - x_2| = 0$, es decir $(x_1 = x_2)$. $\square$

(b) Cota de error

De la desigualdad de Cauchy de la parte (a), fijando (n) y dejando $(m \rightarrow \infty)$ (con $(x_m \rightarrow x_i)$ y continuidad de $(\cdot)$):

$$|x_n - x_i| = \lim_{m \rightarrow \infty} |x_n - x_m| \leq \frac{\lambda^n}{1 - \lambda} |x_1 - x_0|, \quad \forall n \geq 1. \quad \square$$

Problema 4 — Mínimo local de una función convexa es mínimo global

Sea (f) convexa en el conjunto convexo $(S \subseteq \mathbb{R}^n)$: para todo $(x, y \in S)$, $(\theta \in [0, 1])$, $(f((1 - \theta)x + \theta y) \leq (1 - \theta)f(x) + \theta f(y))$.

Sea $(x^* \in S)$ un mínimo local: existe $(\epsilon > 0)$ tal que $(f(x^*) \leq f(z))$ para todo $(z \in S \cap B(x^*, \epsilon))$.

Demostración. Sea $(y \in S)$ arbitrario, $(y \neq x^*)$. Para $(\theta \in (0, 1])$ define $(z_\theta = (1 - \theta)x^* + \theta y)$. Como (S) es convexo, $(z_\theta \in S)$ para todo $(\theta \in [0, 1])$. Además $(|z_\theta - x^*| = \theta |y - x^*| \rightarrow 0)$ cuando $(\theta \rightarrow 0^+)$, así que existe $(\theta_0 > 0)$ (por ejemplo $(\theta_0 = \min\{1, \epsilon / |y - x^*|\})$) tal que $(z_\theta \in B(x^*, \epsilon))$ para todo $(0 < \theta \leq \theta_0)$. Fijemos tal $(\theta \in (0, \theta_0])$.

Por minimalidad local: $(f(x^*) \leq f(z_\theta))$.

Por convexidad: $(f(z_\theta) = f((1 - \theta)x^* + \theta y) \leq (1 - \theta)f(x^*) + \theta f(y))$.

Combinando:

$$f(x^*) \leq (1 - \theta)f(x^*) + \theta f(y) \Rightarrow \theta f(x^*) \leq \theta f(y) \Rightarrow f(x^*) \leq f(y)$$

(dividiendo por $(\theta > 0)$). Como $(y \in S)$ era arbitrario, (x^*) es mínimo global de (f) en (S) . $\square$

Problema 5 — Desigualdad $(M_k(f) \leq \int_a^b f \leq T_k(f))$ para (f) convexa

Basta probarlo en cada subintervalo $[x_i, x_{i+1}]$ de ancho h y sumar sobre los k subintervalos de la partición uniforme (las reglas compuestas son sumas de las reglas simples).

****Dos hechos de convexidad (con $f \in C^2$), aunque solo se usa diferenciabilidad):****

Hecho 1 (la gráfica queda por debajo de la cuerda). Para $x = (1-\theta)x_i + \theta x_{i+1} \in [x_i, x_{i+1}]$ (con $\theta = (x - x_i)/h$), la definición de convexidad da directamente $f(x) \leq (1-\theta)f(x_i) + \theta f(x_{i+1}) =: \ell(x)$ donde ℓ es la recta secante que une $(x_i, f(x_i))$ y $(x_{i+1}, f(x_{i+1}))$.

Hecho 2 (la gráfica queda por encima de la tangente). Sea c cualquier punto y x arbitrario. Para $t \in (0, 1)$, convexidad da $f(c+t(x-c)) \leq (1-t)f(c) + tf(x)$, es decir $\frac{f(c+t(x-c)) - f(c)}{t} \leq f(x) - f(c)$. Tomando $t \rightarrow 0^+$, el lado izquierdo tiende a $f'(c)(x-c)$ (definición de derivada direccional/regla de la cadena), luego $f(x) \geq f(c) + f'(c)(x-c) \quad \forall x$.

Trapezio ($\int_{x_i}^{x_{i+1}} f(x) dx \leq T_k$). Integrando la desigualdad del Hecho 1 sobre $[x_i, x_{i+1}]$: $\int_{x_i}^{x_{i+1}} f(x) dx \leq \int_{x_i}^{x_{i+1}} \ell(x) dx = \frac{h}{2} (f(x_i) + f(x_{i+1}))$, pues $\int \ell$ es exactamente el área del trapecio bajo la secante. Sumando sobre todos los subintervalos: $\int_a^b f(x) dx \leq T_k(f)$.

Punto medio ($\int_{x_i}^{x_{i+1}} f(x) dx \geq M_k$). Sea $c = \frac{x_i + x_{i+1}}{2}$ el punto medio. Aplicando el Hecho 2 con este c e integrando sobre $[x_i, x_{i+1}]$: $\int_{x_i}^{x_{i+1}} f(x) dx \geq \int_{x_i}^{x_{i+1}} [f(c) + f'(c)(x-c)] dx = h[f(c) + f'(c) \underbrace{\int_{x_i}^{x_{i+1}} (x-c) dx}_{=0}] = hf(c)$. El término lineal se anula porque $(x-c)$ es una función impar respecto al punto medio c del intervalo de integración. Sumando sobre todos los subintervalos: $\int_a^b f(x) dx \geq M_k(f)$.

Combinando ambas desigualdades: $\boxed{M_k(f) \leq \int_a^b f(x) dx \leq T_k(f)}$

Verificación: con $f(x) = x^2$ (convexa, $f'' = 2 \geq 0$) en $[0, 2]$, $k=1$: $M_1 = 2 \cdot f(1) = 2$, $T_1 = \frac{2}{2}(f(0) + f(2)) = 4$, e $\int_0^2 x^2 dx = \frac{8}{3} \approx 2.67$. En efecto $2 \leq \frac{8}{3} \leq 4$. ✓

Problema 6 — Cota de error global de un método de un paso general

Método: $y_{k+1} = y_k + h\Phi(t_k, y_k, h)$, $(y_0 = a)$, $(h = 1/N)$, $(t_k = kh)$. Hipótesis: Lipschitz en Φ respecto a y con constante L , y error de truncamiento local $|y(t+h) - y(t) - h\Phi(t, y(t), h)| \leq ch^{p+1}$.

Demostración. Sea $e_k = y_k - y(t_k)$ el error global, $(e_0 = 0)$. Definiendo el error de truncamiento local $\tau_k = y(t_{k+1}) - y(t_k) - h\Phi(t_k, y(t_k), h)$ (con $|\tau_k| \leq ch^{p+1}$), restamos:

$$e_{k+1} = y_{k+1} - y(t_{k+1}) = [y_k + h\Phi(t_k, y_k, h)] - [y(t_k) + h\Phi(t_k, y(t_k), h) + \tau_k] = e_k + h[\Phi(t_k, y_k, h) - \Phi(t_k, y(t_k), h)] - \tau_k$$

Tomando módulo y usando la condición de Lipschitz y $(|\tau_k| \leq ch^{p+1})$:

$$|e_{k+1}| \leq |e_k| + hL|e_k| + |\tau_k| \leq (1+hL)|e_k| + ch^{p+1}.$$

Afirmación (inducción): $(|e_k| \leq \frac{ch^p}{L} \big((1+hL)^k - 1\big))$ para todo $(k \geq 0)$.

Base $(k=0)$: $(e_0=0)$, y el lado derecho es (0) . ✓

Paso inductivo: suponiendo la cota para (k) , $(|e_{k+1}| \leq (1+hL)|e_k| + ch^{p+1}) \leq (1+hL) \frac{ch^p}{L} \big((1+hL)^k - 1\big) + ch^{p+1}$

$$= \frac{ch^p}{L} \big((1+hL)^{k+1} - (1+hL) + 1\big) = \frac{ch^p}{L} \big((1+hL)^{k+1} - 1\big).$$
 Esto completa la inducción.

Conclusión. En $(k=N)$, con $(Nh=1)$: usando $(1+x \leq e^x)$ para todo $(x \in \mathbb{R})$, $((1+hL)^N \leq e^{hLN} = e^L)$. Por lo tanto:

$$|y_N - y(1)| \leq |e_N| \leq \frac{ch^p}{L} \big((1+hL)^N - 1\big) \leq \frac{ch^p}{L} (e^L - 1).$$

Verificación de dimensiones/límite: si $(c \rightarrow 0)$ (método exacto), la cota tiende a (0) , consistente. Si $(h \rightarrow 0)$ con $(p \geq 1)$, la cota $(\rightarrow 0)$: convergencia.

Problema 7 — BVP con advección: $(-u'' + bu' + u = 2x)$, $(u(0) = u(1) = 0)$

Malla uniforme $(x_i = ih)$, $(i=0, \dots, N)$, $(h=1/N)$, incógnitas $(u_1, \dots, u_{N-1})$ $(u_0=0, u_N=0)$.

(a) Diferencias finitas centradas y upwind

Centradas: $(u''(x_i) \approx \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2})$, $(u'(x_i) \approx \frac{u_{i+1} - u_{i-1}}{2h})$. Sustituyendo en la ecuación y multiplicando por (h^2) :

$$-u_{i-1} + 2u_i - u_{i+1} + \frac{bh}{2}(u_{i+1} - u_{i-1}) + h^2u_i = 2h^2x_i$$

$$\Big(-1 + \frac{bh}{2}\Big)u_{i-1} + (2+h^2)u_i + \Big(-1 - \frac{bh}{2}\Big)u_{i+1} = 2h^2x_i, \quad i=1, \dots, N-1.$$

Matriz tridiagonal $((N-1) \times (N-1))$:

$$[A_{\text{cent}}] = \begin{pmatrix} 2+h^2 & -\big(1 - \frac{bh}{2}\big) & & \\ -\big(1 + \frac{bh}{2}\big) & 2+h^2 & -\big(1 - \frac{bh}{2}\big) & \\ & & \ddots & \ddots \\ & & & -\big(1 + \frac{bh}{2}\big) & 2+h^2 \end{pmatrix}.$$

Esta matriz es diagonalmente dominante (fila (i)): $(|2+h^2|)$ vs. $(|1 + \frac{bh}{2}| + |1 - \frac{bh}{2}|)$ solo si $(|bh/2| < 1)$, es decir $(h < 2/|b|)$; si el número de Péclet de malla $(|b|h/2)$ excede 1, aparecen

oscilaciones espurias (no físicas) en la solución discreta — el defecto clásico de la advección centrada en el régimen dominado por convección.

Upwind (caso $b > 0$), análogo para $b < 0$ con diferencia hacia adelante): se reemplaza $u(x_i) \approx \frac{u_{i-1} + b \Delta t u_{i-1}}{\Delta t}$ (diferencia hacia atrás, "aguas arriba" respecto al signo de b). La ecuación queda

$$-u_{i-1} + 2u_i - u_{i+1} + b \Delta t (u_i - u_{i-1}) + h^2 u_{ii} = 2h^2 x_i$$

$$-(1+b \Delta t)u_{i-1} + (2+b \Delta t + h^2)u_i - u_{i+1} = 2h^2 x_i$$

Ahora, para **todo** $h > 0$ (con $b > 0$): $|-(1+b \Delta t)| + |-1| = 2+b \Delta t < 2+b \Delta t + h^2$ (diagonal), es decir la matriz es **estrictamente diagonalmente dominante** sin restricción sobre h . El precio es que la aproximación de u pasa de segundo orden ($O(h^2)$), centrada) a primer orden ($O(h)$), upwind: se introduce "difusión numérica/artificial" que estabiliza el esquema a costa de precisión — el intercambio clásico estabilidad-vs-exactitud en esquemas de advección-difusión.

Condición de frontera $u(1) = \alpha \neq 0$: el operador (la matriz A) no cambia; solo se modifica la última ecuación ($i = N-1$), pues ahora $u_N = \alpha$ es un dato conocido en vez de 0 . El término conocido pasa al lado derecho: para el esquema centrado, $b_{N-1} = 2h^2 x_{N-1} + \frac{1}{2} b \Delta t^2 \alpha$; para el esquema upwind, $b_{N-1} = 2h^2 x_{N-1} + \alpha$ (pues el coeficiente de u_N en esa fila es -1).

(b) Elementos finitos lineales por partes

Forma débil: multiplicando por $v \in H_0^1(0,1)$ e integrando por partes ($v(0)=v(1)=0$) anula el término de frontera):

$$\int_0^1 u' v' dx + b \int_0^1 u' v dx + \int_0^1 u v dx = \int_0^1 2x v dx, \quad \forall v \in H_0^1(0,1)$$

Sea $V_h = \text{span}\{\phi_1, \dots, \phi_{N-1}\}$ con ϕ_i las funciones sombrero estándar ($\phi_i(x_j) = \delta_{ij}$) en la malla uniforme. El problema de Galerkin: hallar $u_h = \sum_j c_j \phi_j \in V_h$ tal que para $i = 1, \dots, N-1$:

$$\sum_j c_j \left[\int_0^1 \phi_j' \phi_i' dx + b \int_0^1 \phi_j' \phi_i dx + \int_0^1 \phi_j \phi_i dx \right] = \int_0^1 2x \phi_i dx$$

Esto produce el sistema $Kc = F$ con:

- **Matriz de rigidez** $(\int \phi_i' \phi_j')$: tridiagonal $\frac{1}{h}(2, -1)$ (el

laplaciano discreto estándar de elementos (P_1)).

- **Término de advección** $(b \int \phi_j' \phi_i)$: matriz antisimétrica que, con

cuadratura exacta e interpolación lineal, reproduce exactamente el término centrado $(\pm b/2)$ del inciso (a): la formulación de Galerkin estándar con (P_1) es, en este problema 1-D con malla uniforme,

algebraicamente equivalente al esquema de diferencias centradas — y por tanto hereda el mismo defecto de oscilaciones para $(|b|h/2 > 1)$ (a menos que se estabilice, p. ej. con SUPG/difusión de línea de corriente).

- **Matriz de masa** $(\int \phi_i \phi_j)$: tridiagonal consistente

$(\frac{h}{6}(4,1))$ (diagonal $(\frac{2h}{3})$, fuera de diagonal $(\frac{h}{6})$).

Tasa de convergencia: por el Lema de Céa y la teoría de interpolación de elementos (P_1) (asumiendo $(u \in H^2(0,1))$ y (h) suficientemente pequeño para la coercividad de la forma bilineal):

$$[|u - u_h|_{H^1(0,1)}] = O(h), \quad |u - u_h|_{L^2(0,1)} = O(h^2)$$

(esta última, de orden óptimo, vía el truco de dualidad de Aubin-Nitsche). Estas son las tasas óptimas para elementos lineales: primer orden en energía (H^1) , segundo orden en (L^2) .