

GMU Numerical Analysis — Agosto 2016

ENUNCIADO — PROBLEMA 1

1. Calculate the following sum by hand in IEEE double precision computer arithmetic, using the Rounding to Nearest Rule:
 $(1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1.$

SOLUCIÓN — PROBLEMA 1

Problema 1 — Aritmética IEEE de doble precisión

Se pide calcular a mano, con redondeo al más cercano ("round to nearest"):

$$(1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1.$$

Paso 1 — suma interna. Los tres sumandos 2^{-51} , 2^{-52} , 2^{-60} tienen bits no nulos en las posiciones (tras el punto binario) 51, 52, 60. La suma $s = 2^{-51} + 2^{-52} + 2^{-60}$ requiere, en su representación binaria normalizada (bit inicial en la posición 51), solo 10 bits de mantisa (de la posición 51 a la 60). Como el doble IEEE tiene 52 bits de mantisa (53 con el bit implícito), s se representa **exactamente**, sin redondeo en este paso.

Paso 2 — suma $1 + s$. El número 1 está en $[1, 2)$, así que un doble en ese rango solo puede resolver 52 bits de fracción **después del punto binario** (posiciones 1 a 52). El valor exacto de $1 + s$ tiene bits en las posiciones 51, 52 (representables) y 60 (fuera de rango: no representable). Hay que redondear.

La media unidad en el último lugar (ULP) en esta escala es 2^{-53} (la mitad de 2^{-52}). Comparemos la contribución "perdida", 2^{-60} , contra ese umbral:

$$2^{-60} = 2^{-53} \cdot 2^{-7} = \frac{2^{-53}}{128} \ll 2^{-53}.$$

Como 2^{-60} es muchísimo menor que medio ULP, el valor exacto $1 + 2^{-51} + 2^{-52} + 2^{-60}$ está mucho más cerca del número representable inferior, $1 + 2^{-51} + 2^{-52}$, que del superior, $1 + 2^{-51} + 2^{-52} + 2^{-52}$. Por la regla de redondeo al más cercano:

$$fl(1 + s) = 1 + 2^{-51} + 2^{-52} = 1 + 3 \cdot 2^{-52}$$

(este valor sí es exactamente representable: los bits 51 y 52 están dentro del rango de 52 bits de mantisa).

Paso 3 — resta final. $fl(1 + s) - 1$. Ambos operandos son exactamente representables y su diferencia, $2^{-51} + 2^{-52} = 3 \cdot 2^{-52}$, también lo es (la resta se realiza sin error adicional, por el Lema de Sterbenz o simplemente porque el resultado cae exactamente en la rejilla de dobles).

$$(1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1 = 2^{-51} + 2^{-52} = 3 \cdot 2^{-52} \approx 6.6613 \times 10^{-16}.$$

Verificación: $2^{-52} \approx 2.22045 \times 10^{-16}$, así que $3 \times 2^{-52} \approx 6.6613 \times 10^{-16}$, y el término $2^{-60} \approx 8.67 \times 10^{-19}$ efectivamente desaparece por redondeo (queda absorbido, es menor que medio ULP en la escala de $1 + s$).



ENUNCIADO — PROBLEMA 2

2. (a) Show how to calculate $\sqrt{5}$ using Newton's method.
- (b) Perform two iterations of Newton's method starting with an initial guess 2.
- (c) Prove that the Newton's method generates a sequence that converges to $\sqrt{5}$ with a quadratic rate.

SOLUCIÓN — PROBLEMA 2

Problema 2 — Newton para $\sqrt{5}$

(a) Fórmula

Sea $f(x) = x^2 - 5$, $f'(x) = 2x$. Newton-Raphson:

$$x_{n+1} = x_n - \frac{x_n^2 - 5}{2x_n} = \frac{x_n^2 + 5}{2x_n} = \frac{1}{2} \left(x_n + \frac{5}{x_n} \right).$$

(b) Dos iteraciones desde $x_0 = 2$

$$x_1 = \frac{1}{2} \left(2 + \frac{5}{2} \right) = \frac{1}{2} \cdot \frac{9}{2} = \frac{9}{4} = 2.25.$$

$$x_2 = \frac{1}{2} \left(\frac{9}{4} + \frac{5}{9/4} \right) = \frac{1}{2} \left(\frac{9}{4} + \frac{20}{9} \right) = \frac{1}{2} \cdot \frac{81 + 80}{36} = \frac{161}{72} \approx 2.236111.$$

Verificación: $\sqrt{5} = 2.2360679 \dots$; en efecto $x_1 = 2.25$ y $x_2 \approx 2.236111$ se acercan rápidamente (el error se cuadra en cada paso, como se muestra a continuación).

(c) Convergencia cuadrática

Sea $e_n = x_n - \sqrt{5}$. Entonces

$$x_{n+1} - \sqrt{5} = \frac{x_n^2 + 5}{2x_n} - \sqrt{5} = \frac{x_n^2 - 2\sqrt{5}x_n + 5}{2x_n} = \frac{(x_n - \sqrt{5})^2}{2x_n} = \frac{e_n^2}{2x_n}.$$

Además, por la desigualdad AM-GM, para $x_0 > 0$ y todo $n \geq 0$:

$$x_{n+1} = \frac{1}{2} \left(x_n + \frac{5}{x_n} \right) \geq \sqrt{x_n \cdot \frac{5}{x_n}} = \sqrt{5},$$

así que $x_n \geq \sqrt{5} > 0$ para todo $n \geq 1$ (los iterados están acotados lejos de cero). Por lo tanto:

$$0 \leq e_{n+1} = \frac{e_n^2}{2x_n} \leq \frac{e_n^2}{2\sqrt{5}} \quad (n \geq 1),$$

lo que muestra $e_{n+1} = O(e_n^2)$: **convergencia cuadrática**, con constante asintótica $C = \lim_{n \rightarrow \infty} e_{n+1}/e_n^2 = 1/(2\sqrt{5}) \approx 0.2236$. ■

ENUNCIADO — PROBLEMA 3

3. (a) Find the solution to the following boundary value problem (BVP)

$$y'' = 2, 0 < t < 1, y(0) = 0, y(1) = 1.$$

using a numerical method of your choice with 3 mesh points 0, 0.5 and 1.

(b) Find the analytical solution to the BVP.

(c) Find the maximum error between the analytical and numerical solutions on $[0, 1]$.

SOLUCIÓN — PROBLEMA 3**Problema 3 — BVP $y'' = 2$, $y(0) = 0$, $y(1) = 1$, malla $\{0, 0.5, 1\}$** **(a) Solución numérica (diferencias finitas centradas, $h = 0.5$)**

En el único nodo interior $x_1 = 0.5$:

$$\frac{y_0 - 2y_1 + y_2}{h^2} = 2 \implies \frac{0 - 2y_1 + 1}{0.25} = 2 \implies 1 - 2y_1 = 0.5 \implies y_1 = 0.25.$$

(b) Solución analítica

$y'' = 2 \Rightarrow y(x) = x^2 + Cx + D$. Con $y(0) = 0$: $D = 0$. Con $y(1) = 1$: $1 + C = 1 \Rightarrow C = 0$. Luego $y(x) = x^2$, y en particular $y(0.5) = 0.25$.

(c) Error máximo

En los tres nodos de malla ($x = 0, 0.5, 1$) la solución numérica coincide **exactamente** con la analítica: $y_0 = 0 = 0^2$, $y_1 = 0.25 = 0.5^2$, $y_2 = 1 = 1^2$. El error nodal máximo es, por lo tanto, **cero**.

Esto no es casualidad: la fórmula de diferencia centrada de segundo orden para u'' tiene error de truncamiento $-\frac{h^2}{12}y^{(4)}(\xi)$, y aquí $y(x) = x^2$ es un polinomio de grado 2, así que $y^{(4)} \equiv 0$: el esquema es exacto en los nodos para esta solución particular.

*(Si en cambio se compara la parábola exacta $y = x^2$ con el interpolante lineal a trozos de los tres valores nodales — es decir, el error entre nodos — el error máximo es $1/16 = 0.0625$, alcanzado en $x = 1/4$ y $x = 3/4$: en $[0, 0.5]$ el interpolante es $\ell(x) = 0.5x$, y $d(x) = \ell(x) - x^2$ tiene máximo en $x = 0.25$ con $d(0.25) = 0.125 - 0.0625 = 0.0625$; por simetría, lo mismo ocurre en $[0.5, 1]$. Pero el error **nodal**, que es lo que típicamente se pide, es 0.)* ■

ENUNCIADO — PROBLEMA 4

4. (a) Write down the Lagrange interpolating polynomial $P(t)$ for the points $(0, 3)$, $(1, 7)$, $(2, 5)$.
- (b) Set up a linear system of equations $A\tilde{x} = \tilde{b}$ which determines the coefficients of the above interpolating polynomial in the monomial basis $\{1, t, t^2\}$.
- (c) Compute the LU -decomposition of the matrix A using partial pivoting.
- (d) Write down the formula for the Householder transformation to eliminate the first column of A .

1

-- 1 of 2 --

SOLUCIÓN — PROBLEMA 4

Problema 4 — Interpolación de Lagrange, sistema de Vandermonde, LU y Householder

Datos: $(0, 3), (1, 7), (2, 5)$.

(a) Polinomio de Lagrange

$$P(t) = 3 \cdot \frac{(t-1)(t-2)}{(0-1)(0-2)} + 7 \cdot \frac{t(t-2)}{(1-0)(1-2)} + 5 \cdot \frac{t(t-1)}{(2-0)(2-1)} = \frac{3}{2}(t-1)(t-2) - 7t(t-2) + \frac{5}{2}t(t-1).$$

Expandiendo: $\frac{3}{2}(t^2-3t+2)-7(t^2-2t)+\frac{5}{2}t(t-1) = (1.5-7+2.5)t^2+(-4.5+14-2.5)t+3 = -3t^2+7t+3.$

$$\boxed{P(t) = -3t^2 + 7t + 3.}$$

Verificación: $P(0) = 3 \checkmark, P(1) = -3 + 7 + 3 = 7 \checkmark, P(2) = -12 + 14 + 3 = 5 \checkmark.$

(b) Sistema de Vandermonde

Con $P(t) = c_0 + c_1t + c_2t^2$, imponiendo $P(t_i) = y_i$:

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix}, \quad b = \begin{pmatrix} 3 \\ 7 \\ 5 \end{pmatrix}, \quad Ax = b, \quad x = (c_0, c_1, c_2)^T.$$

(En efecto $x = (3, 7, -3)^T$ resuelve $Ax = b$, coincidiendo con (a).)

(c) Factorización LU con pivoteo parcial

Columna 1 (entradas 1, 1, 1): empate; no hay intercambio, se usa la fila 1 como pivote.

Multiplicadores $m_{21} = m_{31} = 1$. Restando la fila 1 (escalada) de las filas 2 y 3:

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 2 & 4 \end{pmatrix}.$$

Columna 2 (submatriz filas 2–3: entradas 1, 2): el pivote parcial exige el de mayor módulo, 2 (fila 3); se intercambian las filas 2 y 3:

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 1 & 1 \end{pmatrix}.$$

Multiplicador $m_{32} = 1/2$: fila 3 $\leftarrow$ fila 3 $-\frac{1}{2}$ · fila 2: $(0, 1 - 1, 1 - 2) = (0, 0, -1)$.

$$U = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 0 & -1 \end{pmatrix}, \quad L = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & \frac{1}{2} & 1 \end{pmatrix}, \quad P = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \text{ (intercambia filas 2 y 3)}.$$

Verificación ($PA = LU$):

$$PA = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 1 & 1 \end{pmatrix}, \quad LU = \begin{pmatrix} 1 & 0 & 0 \\ 1 \cdot 1 & 1 \cdot 2 & 1 \cdot 4 \\ 1 \cdot 1 + \frac{1}{2} \cdot 0 & \frac{1}{2} \cdot 2 & \frac{1}{2} \cdot 4 - 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 1 & 1 \end{pmatrix}.$$

Coinciden. ■

(d) Transformación de Householder para eliminar la columna 1

Sea $a = (1, 1, 1)^T$ (columna 1 de A), $\|a\|_2 = \sqrt{3}$. Se elige $\alpha = -\text{sign}(a_1)\|a\|_2 = -\sqrt{3}$ (signo opuesto a a_1 , para evitar cancelación catastrófica). El vector de Householder:

$$v = a - \alpha e_1 = (1 + \sqrt{3}, 1, 1)^T, \quad v^T v = (1 + \sqrt{3})^2 + 1 + 1 = 6 + 2\sqrt{3}.$$

La transformación:

$$H = I - \frac{2}{v^T v} vv^T = I - \frac{1}{3 + \sqrt{3}} vv^T,$$

que satisface $Ha = \alpha e_1 = (-\sqrt{3}, 0, 0)^T$, eliminando (llevando a cero) las entradas 2 y 3 de la primera columna, como se requiere. H es simétrica y ortogonal ($H^T H = I$), como toda reflexión de Householder.

ENUNCIADO — PROBLEMA 5

SOLUCIÓN — PROBLEMA 5

Problema 5 — Algoritmo QR para valores propios

Recurrencia: $A_0 = A$; en cada paso, $A_{k-1} = Q_k R_k$ (factorización QR), $A_k := R_k Q_k$.

(a) Todas las A_k tienen los mismos valores propios

De $A_{k-1} = Q_k R_k$ se sigue $R_k = Q_k^{-1} A_{k-1} = Q_k^T A_{k-1}$ (pues Q_k es ortogonal). Sustituyendo en $A_k = R_k Q_k$:

$$A_k = Q_k^T A_{k-1} Q_k,$$

es decir, A_k es **ortogonalmente semejante** a A_{k-1} . Como matrices semejantes tienen el mismo polinomio característico (y por tanto los mismos valores propios: si $A_{k-1}v = \lambda v$, entonces $A_k(Q_k^{-1}v) = Q_k^{-1}A_{k-1}v = \lambda Q_k^{-1}v$), por inducción

$$A_k = (Q_1 \cdots Q_k)^T A_0 (Q_1 \cdots Q_k)$$

es semejante a $A_0 = A$ para todo $k \geq 0$. Luego todas las A_k comparten el mismo espectro que A .

■

(b) Determinación de vectores propios

Sea $Q^{(m)} := Q_1 Q_2 \cdots Q_m$ (matriz ortogonal, producto acumulado de los factores Q de cada paso). De la parte (a), $A_m = (Q^{(m)})^T A_0 Q^{(m)} = \Lambda$ (diagonal, por hipótesis). Multiplicando por $Q^{(m)}$ a la izquierda:

$$A_0 Q^{(m)} = Q^{(m)} \Lambda.$$

Escribiendo esta igualdad columna por columna, si q_i es la i -ésima columna de $Q^{(m)}$ y $\lambda_i = \Lambda_{ii}$:

$$A_0 q_i = \lambda_i q_i,$$

es decir, **las columnas de $Q^{(m)} = Q_1 Q_2 \cdots Q_m$ son los vectores propios de A** , correspondientes a los valores propios en la diagonal de $\Lambda = A_m$. (Como A es simétrica con valores propios distintos, estos vectores propios son automáticamente ortonormales, consistente con que $Q^{(m)}$ es ortogonal.) En la práctica: se acumula el producto de los factores Q_k de cada iteración; ese producto converge a la matriz de vectores propios. ■

ENUNCIADO — PROBLEMA 6

5. Consider the QR Iteration algorithm for a matrix $A = A_0$

for $k=1:m$

 Compute the QR factorization: $Q_k R_k = A_{k-1}$

 Set $A_k = R_k Q_k$

end

(a) Show that the matrices A_k all have the same eigenvalues.

(b) Assume that A is a real symmetric matrix with distinct eigenvalues and that A_m is equal to a diagonal matrix Λ . Describe how to determine the eigenvectors of A from the algorithm.

SOLUCIÓN — PROBLEMA 6

Problema 6 — Cuadratura de 3 puntos simétrica (Gauss-Legendre)

$$\int_{-1}^1 f(x) dx = w_1 f(-a) + w_2 f(0) + w_3 f(a).$$

(a) Coeficientes de máxima exactitud

Por simetría, si se impone exactitud para $f = x$: $-aw_1 + aw_3 = 0 \Rightarrow w_1 = w_3$ (asumiendo $a \neq 0$); entonces $f = x^3$ se satisface automáticamente ($a^3(w_3 - w_1) = 0 = \int_{-1}^1 x^3 dx$), sin dar información nueva. Quedan tres incógnitas efectivas $w_1 (= w_3), w_2, a$, determinadas por exactitud en $f = 1, x^2, x^4$:

$$f = 1 : \quad 2 = 2w_1 + w_2.$$

$$f = x^2 : \quad \frac{2}{3} = 2w_1 a^2.$$

$$f = x^4 : \quad \frac{2}{5} = 2w_1 a^4.$$

Dividiendo la tercera entre la segunda: $a^2 = \frac{2/5}{2/3} = \frac{3}{5}$, así $a = \sqrt{3/5}$. De $2w_1 a^2 = 2/3$: $w_1 = \frac{1/3}{a^2} = \frac{1/3}{3/5} = \frac{5}{9}$. De la primera: $w_2 = 2 - 2w_1 = 2 - \frac{10}{9} = \frac{8}{9}$.

$$a = \sqrt{\frac{3}{5}}, \quad w_1 = w_3 = \frac{5}{9}, \quad w_2 = \frac{8}{9}.$$

Esta es exactamente la **regla de cuadratura gaussiana de 3 puntos (Gauss-Legendre)**, exacta para polinomios hasta grado 5 (verificación: $f = x^6$ da $2w_1 a^6 = 2 \cdot \frac{5}{9} \cdot (3/5)^3 = 0.24 \neq \frac{2}{7} \approx 0.2857$, así que grado 6 ya falla — el grado máximo de exactitud es $2n - 1 = 5$ con $n = 3$ nodos, como predice la teoría de cuadratura gaussiana).

(b) Aplicación a $\int_0^1 \frac{1}{x+1} dx$

Cambio de variable $x = \frac{t+1}{2}$ ($t \in [-1, 1] \rightarrow x \in [0, 1]$), $dx = dt/2$:

$$\int_0^1 \frac{dx}{x+1} = \int_{-1}^1 \frac{1}{\frac{t+1}{2} + 1} \cdot \frac{dt}{2} = \int_{-1}^1 \frac{dt}{t+3} =: \int_{-1}^1 g(t) dt.$$

Aplicando la regla con $a = \sqrt{0.6} \approx 0.774597$:

$$g(-a) = \frac{1}{3-a} \approx \frac{1}{2.225403} \approx 0.449339, \quad g(0) = \frac{1}{3} \approx 0.333333, \quad g(a) = \frac{1}{3+a} \approx \frac{1}{3.774597} \approx 0.264928.$$

$$\int_{-1}^1 g \, dt \approx \frac{5}{9}(0.449339 + 0.264928) + \frac{8}{9}(0.333333) \approx 0.555556 \times 0.714267 + 0.888889 \times 0.333333 \approx 0.396815 + 0.296296 = 0.693111.$$

Verificación: el valor exacto es $\int_0^1 \frac{dx}{x+1} = \ln 2 = 0.693147 \dots$. El error de la cuadratura, $\approx 3.6 \times 10^{-5}$, es minúsculo, consistente con la exactitud de grado 5 de la regla aplicada a una función suave no polinómica. ■

ENUNCIADO — PROBLEMA 7

6. A quadrature rule is given by:

$$\int_{-1}^1$$

$$f(x) dx = w_1 f(-a) + w_2 f(0) + w_3 f(a)$$

(a) Find w_1 , w_2 , w_3 , a that will make this quadrature rule exact for all polynomials of as high a degree as possible.

(b) Use this quadrature rule to explain how to numerically compute

$$\int_{-1}^1$$

$$0$$

$$1$$

$$x + 1 dx.$$

SOLUCIÓN — PROBLEMA 7

Problema 7 — Cota de error del Euler explícito no lineal

$y' = a + by + c \cos y$, $y(0) = 1$, $a, b, c > 0$, $\max_{[0,1]} |y''| = M < \infty$. Euler: $y_{k+1} = y_k + h\Phi(y_k)$, $\Phi(y) = a + by + c \cos y$, $h = 1/N$.

Constante de Lipschitz de Φ : $\Phi'(y) = b - c \sin y$, así que $|\Phi'(y)| \leq b + c$ (pues $|\sin y| \leq 1$ y $b, c > 0$). Por el teorema del valor medio, Φ es Lipschitz en y con constante $L = b + c$.

Error de truncamiento local: como $\Phi = f$ (Euler explícito estándar), por Taylor con residuo de Lagrange:

$$y(t_{k+1}) = y(t_k) + hy'(t_k) + \frac{h^2}{2}y''(\xi_k) = y(t_k) + h\Phi(t_k, y(t_k)) + \frac{h^2}{2}y''(\xi_k),$$

así que $\tau_k = \frac{h^2}{2}y''(\xi_k)$, con $|\tau_k| \leq \frac{M}{2}h^2$.

Recursión del error global ($e_k = y_k - y(t_k)$, $e_0 = 0$), igual que en el Problema 6 del examen de enero de 2016:

$$|e_{k+1}| \leq (1 + hL)|e_k| + \frac{M}{2}h^2,$$

y por inducción (idéntica a la del problema análogo):

$$|e_k| \leq \frac{(M/2)h}{L} [(1 + hL)^k - 1] = \frac{Mh}{2L} [(1 + hL)^k - 1].$$

En $k = N$, $Nh = 1$, y usando $1 + x \leq e^x$: $(1 + hL)^N \leq e^{hLN} = e^L = e^{b+c}$. Por lo tanto:

$$|y(1) - y_N| = |e_N| \leq \frac{Mh}{2(b+c)} (e^{b+c} - 1) \leq \frac{Mh}{2(b+c)} e^{b+c},$$

pues $e^{b+c} - 1 < e^{b+c}$ trivialmente. Esto establece la cota pedida (de hecho una cota ligeramente más fuerte):

$$\boxed{|y(1) - y_N| \leq \frac{Mhe^{b+c}}{2(b+c)}}. \blacksquare$$

ENUNCIADO — PROBLEMA 8

7. Consider the initial value problem

$\frac{dy}{dt} = a + by(t) + c \cos y(t), 0 \leq t \leq 1$

where $y(0) = 1$ and $a, b, c > 0$ are constants. Let us suppose that the solution satisfies

$\max_{0 \leq t \leq 1} |y''(t)| = M < \infty$.

Consider the approximation $y_{k+1} = y_k + (a + by_k + c \cos(y_k))h$

for $k = 0, 1, 2, \dots, N-1$ and let $y_0 = y(0)$ and $h = 1/N$.

Prove that

$$|y(1) - y_N| \leq M h e^{b+c}.$$

$$2(b+c).$$

2

-- 2 of 2 --

SOLUCIÓN — PROBLEMA 8

No hay solución disponible.