

ENUNCIADO DEL EXAMEN

Numerical Analysis Preliminary Examination questions

August 2016

Instructions: NO CALCULATORS are allowed. This examination contains seven problems, each worth 20 points. Do any five of the seven problems. Show your work. Clearly indicate which five are to be graded.

PLEASE GRADE PROBLEMS: 1 2 3 4 5 6 7

1. Calculate the following sum by hand in IEEE double precision computer arithmetic, using the Rounding to Nearest Rule:

$$(1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1.$$

2. (a) Show how to calculate $\sqrt{5}$ using Newton's method.

(b) Perform two iterations of Newton's method starting with an initial guess 2.

(c) Prove that the Newton's method generates a sequence that converges to $\sqrt{5}$ with a quadratic rate.

3. (a) Find the solution to the following boundary value problem (BVP)

$$y'' = 2, 0 < t < 1, y(0) = 0, y(1) = 1.$$

using a numerical method of your choice with 3 mesh points 0, 0.5 and 1.

(b) Find the analytical solution to the BVP.

(c) Find the maximum error between the analytical and numerical solutions on $[0, 1]$.

4. (a) Write down the Lagrange interpolating polynomial $P(t)$ for the points $(0, 3)$, $(1, 7)$, $(2, 5)$.

(b) Set up a linear system of equations $A\tilde{x} = \tilde{b}$ which determines the coefficients of

the above interpolating polynomial in the monomial basis $\{1, t, t^2\}$.

(c) Compute the LU -decomposition of the matrix A using partial pivoting.

(d) Write down the formula for the Householder transformation to eliminate the first column of A.

1

5. Consider the QR Iteration algorithm for a matrix $A = A_0$

for $k=1:m$

Compute the QR factorization: $Q_k R_k = A_{k-1}$

Set $A_k = R_k Q_k$

end

(a) Show that the matrices A_k all have the same eigenvalues.

(b) Assume that A is a real symmetric matrix with distinct eigenvalues and that A_m is equal to a diagonal matrix Λ . Describe how to determine the eigenvectors of A from the algorithm.

6. A quadrature rule is given by:

$\int_{-1}^1 f(x) dx$

$\approx w_1 f(-a) + w_2 f(0) + w_3 f(a)$

(a) Find w_1, w_2, w_3, a that will make this quadrature rule exact for all polynomials of as high a degree as possible.

(b) Use this quadrature rule to explain how to numerically compute

$\int_0^1$

0

1

$x + 1 \, dx$.

7. Consider the initial value problem

dy

$dt = a + by(t) + c \cos y(t), 0 \leq t \leq 1$

where $y(0) = 1$ and $a, b, c > 0$ are constants. Let us suppose that the solution satisfies

$\max$

$0 \leq t \leq 1 \, |y''(t)| = M < \infty$. Consider the approximation $y_{k+1} = y_k + (a + by_k + c \cos(y_k))h$

for $k = 0, 1, 2, \dots, N - 1$ and let $y_0 = y(0)$ and $h = 1$

N . Prove that

$|y(1) - y_N| \leq M h e^{b+c}$

$2(b + c)$.

2

SOLUCIÓN DETALLADA

Solución — GMU Numerical Analysis Preliminary Exam, Agosto 2016

Formato: resolver 5 de 7 problemas, libro/notas cerrados, sin calculadora.

Sección principal del temario: examen mixto con fuerte peso en álgebra lineal numérica (LU con pivoteo, transformación de Householder, algoritmo QR para valores propios) y en aritmética computacional (punto flotante IEEE), más los temas adicionales de interpolación de Lagrange, cuadratura gaussiana y error global de un método de un paso (Euler explícito no lineal).

Problema 1 — Aritmética IEEE de doble precisión

Se pide calcular a mano, con redondeo al más cercano ("round to nearest"): $\lfloor (1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1 \rfloor$.

Paso 1 — suma interna. Los tres sumandos $(2^{-51}, 2^{-52}, 2^{-60})$ tienen bits no nulos en las posiciones (tras el punto binario) $(51, 52, 60)$. La suma $(s = 2^{-51} + 2^{-52} + 2^{-60})$ requiere, en su representación binaria normalizada (bit inicial en la posición 51), solo 10 bits de mantisa (de la posición 51 a la 60). Como el doble IEEE tiene 52 bits de mantisa (53 con el bit implícito), (s) se representa **exactamente**, sin redondeo en este paso.

Paso 2 — suma $(1+s)$. El número (1) está en $([1, 2))$, así que un doble en ese rango solo puede resolver 52 bits de fracción **después del punto binario** (posiciones (1) a (52)). El valor exacto de $(1+s)$ tiene bits en las posiciones $(51, 52)$ (representables) y (60) (fuera de rango: no representable). Hay que redondear.

La media unidad en el último lugar (ULP) en esta escala es (2^{-53}) (la mitad de (2^{-52})). Comparemos la contribución "perdida", (2^{-60}) , contra ese umbral: $(2^{-60} = 2^{-53} \cdot 2^{-7} = \frac{2^{-53}}{128} \ll 2^{-53})$. Como (2^{-60}) es muchísimo menor que medio ULP, el valor exacto $(1 + 2^{-51} + 2^{-52} + 2^{-60})$ está mucho más cerca del número representable inferior, $(1 + 2^{-51} + 2^{-52})$, que del superior, $(1 + 2^{-51} + 2^{-52} + 2^{-52})$. Por la regla de redondeo al más cercano: $\lfloor (1+s) \rfloor = 1 + 2^{-51} + 2^{-52} = 1 + 3 \cdot 2^{-52}$ (este valor sí es exactamente representable: los bits (51) y (52) están dentro del rango de 52 bits de mantisa).

Paso 3 — resta final. $\lfloor (1+s) - 1 \rfloor$. Ambos operandos son exactamente representables y su diferencia, $(2^{-51} + 2^{-52} = 3 \cdot 2^{-52})$, también lo es (la resta se realiza sin error adicional, por el Lema de Sterbenz o simplemente porque el resultado cae exactamente en la rejilla de dobles).

$$\boxed{(1 + (2^{-51} + 2^{-52} + 2^{-60})) - 1} = 2^{-51} + 2^{-52} = 3 \cdot 2^{-52} \approx 6.6613 \times 10^{-16}.$$

Verificación: $(2^{-52} \approx 2.22045 \times 10^{-16})$, así que $(3 \times 2^{-52} \approx 6.6613 \times 10^{-16})$, y el término $2^{-60} \approx 8.67 \times 10^{-19}$ efectivamente desaparece por redondeo (queda absorbido, es menor que medio ULP en la escala de $(1+s)$).

Problema 2 — Newton para $(\sqrt{5})$

(a) Fórmula

Sea $(f(x)=x^2-5)$, $(f'(x)=2x)$. Newton-Raphson: $[x_{n+1}=x_n-\frac{x_n^2-5}{2x_n}=\frac{x_n^2+5}{2x_n}=\frac{1}{2}\left(x_n+\frac{5}{x_n}\right)]$

(b) Dos iteraciones desde $(x_0=2)$

$$[x_1=\frac{1}{2}\left(2+\frac{5}{2}\right)=\frac{1}{2}\cdot\frac{9}{2}=\frac{9}{4}=2.25.]$$

$$[x_2=\frac{1}{2}\left(\frac{9}{4}+\frac{5}{9/4}\right)=\frac{1}{2}\left(\frac{9}{4}+\frac{20}{9}\right)=\frac{1}{2}\cdot\frac{81+80}{36}=\frac{161}{72}\approx 2.236111.]$$

Verificación: $(\sqrt{5}=2.2360679\dots)$; en efecto $(x_1=2.25)$ y $(x_2\approx 2.236111)$ se acercan rápidamente (el error se cuadra en cada paso, como se muestra a continuación).

(c) Convergencia cuadrática

Sea $(e_n=x_n-\sqrt{5})$. Entonces

$$[x_{n+1}-\sqrt{5}=\frac{x_n^2+5}{2x_n}-\sqrt{5}=\frac{x_n^2-2\sqrt{5}x_n+5}{2x_n}=\frac{(x_n-\sqrt{5})^2}{2x_n}=\frac{e_n^2}{2x_n}.]$$

Además, por la desigualdad AM-GM, para $(x_0>0)$ y todo $(n\geq 0)$: $[x_{n+1}=\frac{1}{2}\left(x_n+\frac{5}{x_n}\right)\geq\sqrt{x_n\cdot\frac{5}{x_n}}=\sqrt{5},]$ así que $(x_n\geq\sqrt{5}>0)$ para todo $(n\geq 1)$ (los iterados están acotados lejos de cero). Por lo tanto:

$$[0\leq e_{n+1}=\frac{e_n^2}{2x_n}\leq\frac{e_n^2}{2\sqrt{5}}\quad (n\geq 1),]$$

lo que muestra $(e_{n+1}=O(e_n^2))$: **convergencia cuadrática**, con constante asintótica $(C=\lim_{n\rightarrow\infty}e_{n+1}/e_n^2=1/(2\sqrt{5})\approx 0.2236)$. $(\blacksquare)$

Problema 3 — BVP $(y''=2)$, $(y(0)=0)$, $(y(1)=1)$, malla $(\{0,0.5,1\})$

(a) Solución numérica (diferencias finitas centradas, $(h=0.5)$)

En el único nodo interior $(x_1=0.5)$: $[\frac{y_0-2y_1+y_2}{h^2}=2\rightarrow\frac{0-2y_1+1}{0.25}=2\rightarrow 1-2y_1=0.5\rightarrow y_1=0.25.]$

(b) Solución analítica

$y'' = 2 \Rightarrow y(x) = x^2 + Cx + D$. Con $(y(0)=0)$: $(D=0)$. Con $(y(1)=1)$: $1+C=1 \Rightarrow C=0$.
Luego $y(x) = x^2$, y en particular $y(0.5) = 0.25$.

(c) Error máximo

En los tres nodos de malla $(x=0, 0.5, 1)$ la solución numérica coincide **exactamente** con la analítica: $(y_0=0=0^2)$, $(y_1=0.25=0.5^2)$, $(y_2=1=1^2)$. El error nodal máximo es, por lo tanto, **cero**.

Esto no es casualidad: la fórmula de diferencia centrada de segundo orden para (u'') tiene error de truncamiento $(-\frac{h^2}{12}y^{(4)}(\xi))$, y aquí $(y(x)=x^2)$ es un polinomio de grado (2) , así que $(y^{(4)} \equiv 0)$: el esquema es exacto en los nodos para esta solución particular.

*(Si en cambio se compara la parábola exacta $(y=x^2)$ con el interpolante lineal a trozos de los tres valores nodales — es decir, el error entre nodos — el error máximo es $(1/16=0.0625)$, alcanzado en $(x=1/4)$ y $(x=3/4)$: en $([0, 0.5])$ el interpolante es $(\ell(x)=0.5x)$, y $(d(x)=\ell(x)-x^2)$ tiene máximo en $(x=0.25)$ con $(d(0.25)=0.125-0.0625=0.0625)$; por simetría, lo mismo ocurre en $([0.5, 1])$. Pero el error **nodal**, que es lo que típicamente se pide, es (0) .)*

Problema 4 — Interpolación de Lagrange, sistema de Vandermonde, LU y Householder

Datos: $((0,3), (1,7), (2,5))$.

(a) Polinomio de Lagrange

$$P(t) = 3 \cdot \frac{(t-1)(t-2)}{(0-1)(0-2)} + 7 \cdot \frac{t(t-2)}{(1-0)(1-2)} + 5 \cdot \frac{t(t-1)}{(2-0)(2-1)} \\ = \frac{3}{2}(t-1)(t-2) - 7t(t-2) + 5t(t-1).$$

$$\text{Expandiendo: } \frac{3}{2}(t^2-3t+2) - 7(t^2-2t) + 5t(t-1) = (1.5-7+2.5)t^2 + (-4.5+14-2.5)t + 3 = -3t^2+7t+3.$$

$$\boxed{P(t) = -3t^2 + 7t + 3}$$

Verificación: $(P(0)=3) \checkmark$, $(P(1)=-3+7+3=7) \checkmark$, $(P(2)=-12+14+3=5) \checkmark$.

(b) Sistema de Vandermonde

Con $(P(t)=c_0+c_1t+c_2t^2)$, imponiendo $(P(t_i)=y_i)$:

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix}, \quad b = \begin{pmatrix} 3 \\ 7 \\ 5 \end{pmatrix}, \quad Ax=b, \quad x = (c_0, c_1, c_2)^T.$$

(En efecto $(x=(3,7,-3)^T)$ resuelve $(Ax=b)$, coincidiendo con (a).)

(c) Factorización (LU) con pivoteo parcial

Columna 1 (entradas $(1,1,1)$): empate; no hay intercambio, se usa la fila 1 como pivote. Multiplicadores $(m_{21}=m_{31}=1)$. Restando la fila 1 (escalada) de las filas 2 y 3:

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 2 & 4 \end{pmatrix}.$$

Columna 2 (submatriz filas 2–3: entradas $(1,2)$): el pivote parcial exige el de mayor módulo, (2) (fila 3); **se intercambian las filas 2 y 3**:

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 1 & 1 \end{pmatrix}.$$

Multiplicador $(m_{32}=1/2)$: fila 3 $\leftarrow$ fila 3 $-\frac{1}{2}$ fila 2: $((0,1,1)-2(0,2,4))$.

$$U = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 0 & -1 \end{pmatrix}, \quad$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & \frac{1}{2} & 1 \end{pmatrix}, \quad$$

$$P = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} \quad (\text{intercambia filas 2 y 3}).$$

Verificación $(PA=LU)$: $PA = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 1 & 1 \end{pmatrix}, \quad LU = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & \frac{1}{2} & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 4 \\ 0 & 0 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 1 & 1 \end{pmatrix}.$ Coinciden. $\blacksquare$

(d) Transformación de Householder para eliminar la columna 1

Sea $a = (1,1,1)^T$ (columna 1 de (A)), $|a|_2 = \sqrt{3}$. Se elige $\alpha = -\text{sign}(a_1)|a|_2 = -\sqrt{3}$ (signo opuesto a a_1), para evitar cancelación catastrófica). El vector de Householder:

$$v = a - \alpha e_1 = (1 + \sqrt{3}, 1, 1)^T, \quad v^T v = (1 + \sqrt{3})^2 + 1 + 1 = 6 + 2\sqrt{3}.$$

La transformación:

$$H = I - \frac{2}{v^T v} vv^T = I - \frac{1}{3 + \sqrt{3}} vv^T,$$

que satisface $(Ha = \alpha e_1 = (-\sqrt{3}, 0, 0)^T)$, eliminando (llevando a cero) las entradas (2) y (3) de la primera columna, como se requiere. (H) es simétrica y ortogonal $(H^T H = I)$, como toda reflexión de Householder.

Problema 5 — Algoritmo QR para valores propios

Recurrencia: $(A_0 = A)$; en cada paso, $(A_{k-1} = Q_k R_k)$ (factorización QR), $(A_k = R_k Q_k)$.

(a) Todas las (A_k) tienen los mismos valores propios

De $(A_{k-1} = Q_k R_k)$ se sigue $(R_k = Q_k^{-1} A_{k-1} = Q_k^T A_{k-1})$ (pues (Q_k) es ortogonal). Sustituyendo en $(A_k = R_k Q_k)$:

$$A_k = Q_k^T A_{k-1} Q_k,$$

es decir, (A_k) es **ortogonalmente semejante** a (A_{k-1}) . Como matrices semejantes tienen el mismo polinomio característico (y por tanto los mismos valores propios: si $(A_{k-1}v = \lambda v)$, entonces

$A_k(Q_k^T v) = Q_k^T A_{k-1} v = \lambda Q_k^T v$, por inducción

$$A_k = (Q_1 \cdots Q_k)^T A_0 (Q_1 \cdots Q_k)$$

es semejante a $(A_0 = A)$ para todo $(k \geq 0)$. Luego todas las (A_k) comparten el mismo espectro que (A) . $\square$

(b) Determinación de vectores propios

Sea $(Q^{\{m\}} := Q_1 Q_2 \cdots Q_m)$ (matriz ortogonal, producto acumulado de los factores (Q) de cada paso). De la parte (a), $(A_m = (Q^{\{m\}})^T A_0 Q^{\{m\}} = \Lambda)$ (diagonal, por hipótesis). Multiplicando por $(Q^{\{m\}})$ a la izquierda:

$$A_0 Q^{\{m\}} = Q^{\{m\}} \Lambda$$

Escribiendo esta igualdad columna por columna, si (q_i) es la (i) -ésima columna de $(Q^{\{m\}})$ y $(\lambda_i = \Lambda_{ii})$:

$$A_0 q_i = \lambda_i q_i$$

es decir, las columnas de $(Q^{\{m\}} = Q_1 Q_2 \cdots Q_m)$ son los vectores propios de (A) , correspondientes a los valores propios en la diagonal de $(\Lambda = A_m)$. (Como (A) es simétrica con valores propios distintos, estos vectores propios son automáticamente ortonormales, consistente con que $(Q^{\{m\}})$ es ortogonal.) En la práctica: se acumula el producto de los factores (Q_k) de cada iteración; ese producto converge a la matriz de vectores propios. $\square$

Problema 6 — Cuadratura de 3 puntos simétrica (Gauss-Legendre)

$$\int_{-1}^1 f(x) dx = w_1 f(-a) + w_2 f(0) + w_3 f(a)$$

(a) Coeficientes de máxima exactitud

Por simetría, si se impone exactitud para $(f=x)$: $-aw_1 + aw_3 = 0 \Rightarrow w_1 = w_3$ (asumiendo $a \neq 0$); entonces $f=x^3$ se satisface automáticamente $(a^3(w_3 - w_1) = 0 = \int_{-1}^1 x^3 dx)$, sin dar información nueva. Quedan tres incógnitas efectivas $(w_1 (=w_3), w_2, a)$, determinadas por exactitud en $(f=1, x^2, x^4)$:

$$f=1: 2 = 2w_1 + w_2 \quad f=x^2: \frac{2}{3} = 2w_1 a^2 \quad f=x^4: \frac{25}{8} = 2w_1 a^4$$

Dividiendo la tercera entre la segunda: $a^2 = \frac{25}{8} \cdot \frac{3}{2} = \frac{35}{8}$, así $a = \sqrt{\frac{35}{8}}$. De $(2w_1 a^2 = \frac{2}{3})$: $(w_1 = \frac{1}{3} \cdot \frac{3}{a^2} = \frac{1}{3} \cdot \frac{8}{35} = \frac{8}{105})$. De la primera: $(w_2 = 2 - 2w_1 = 2 - \frac{16}{105} = \frac{89}{105})$.

$$\boxed{a = \sqrt{\frac{35}{8}}, w_1 = w_3 = \frac{8}{105}, w_2 = \frac{89}{105}}$$

Esta es exactamente la regla de cuadratura gaussiana de 3 puntos (Gauss-Legendre), exacta para polinomios hasta grado (5) (verificación: $(f=x^6)$ da $\int_{-1}^1 x^6 dx = \frac{2}{7}$ y $w_1 f(-a) + w_2 f(0) + w_3 f(a) = \frac{8}{105} \cdot 2 \cdot \frac{35}{8} = \frac{2}{7}$).

($2w_1a^6=2\cdot\frac{59}{5}\cdot(3/5)^3=0.24\neq\frac{27}{100}\approx0.2857$), así que grado (6) ya falla — el grado máximo de exactitud es $(2n-1=5)$ con $(n=3)$ nodos, como predice la teoría de cuadratura gaussiana).

(b) Aplicación a $(\int_0^1 \frac{1}{x+1} dx)$

Cambio de variable $(x=\frac{t+1}{2})$ ($(t\in[-1,1]\rightarrow x\in[0,1])$), $(dx=dt/2)$:

$$\int_0^1 \frac{dx}{x+1} = \int_{-1}^1 \frac{1}{\frac{t+1}{2}+1} \cdot \frac{dt}{2} = \int_{-1}^1 \frac{dt}{t+3} = \int_{-1}^1 g(t) dt.$$

Aplicando la regla con $(a=\sqrt{0.6}\approx0.774597)$:

$$g(-a)=\frac{1}{3-a}\approx\frac{1}{2.225403}\approx0.449339, \quad g(0)=\frac{1}{3}\approx0.333333, \quad g(a)=\frac{1}{3+a}\approx\frac{1}{3.774597}\approx0.264928.$$

$$\int_{-1}^1 g(t) dt \approx \frac{59}{90}(0.449339+0.264928)+\frac{89}{90}(0.333333) \approx 0.555556 \times 0.714267 + 0.888889 \times 0.333333 \approx 0.396815 + 0.296296 = 0.693111.$$

Verificación: el valor exacto es $(\int_0^1 \frac{dx}{x+1} = \ln 2 = 0.693147\dots)$ El error de la cuadratura, $(\approx 3.6 \times 10^{-5})$, es minúsculo, consistente con la exactitud de grado 5 de la regla aplicada a una función suave no polinómica. $(\blacksquare)$

Problema 7 — Cota de error del Euler explícito no lineal

$(y'=a+by+c\cos y)$, $(y(0)=1)$, $(a,b,c>0)$, $(\max_{[0,1]}|y''|=M<\infty)$. Euler: $(y_{k+1}=y_k+h\Phi(y_k))$, $(\Phi(y)=a+by+c\cos y)$, $(h=1/N)$.

Constante de Lipschitz de (Φ) : $(\Phi'(y)=b-c\sin y)$, así que $(|\Phi'(y)|\leq b+c)$ (pues $(|\sin y|\leq 1)$ y $(b,c>0)$). Por el teorema del valor medio, (Φ) es Lipschitz en (y) con constante $(L=b+c)$.

Error de truncamiento local: como $(\Phi=f)$ (Euler explícito estándar), por Taylor con residuo de Lagrange:

$$y(t_{k+1})=y(t_k)+hy'(t_k)+\frac{h^2}{2}y''(\xi_k)=y(t_k)+h\Phi(t_k,y(t_k))+\frac{h^2}{2}y''(\xi_k), \quad \text{así que } (\tau_k=\frac{h^2}{2}y''(\xi_k)), \text{ con } (|\tau_k|\leq\frac{M}{2}h^2).$$

Recursión del error global $(e_k=y_k-y(t_k))$, $(e_0=0)$, igual que en el Problema 6 del examen de enero de 2016: $(|e_{k+1}|\leq(1+hL)|e_k|+\frac{Mh^2}{2})$ y por inducción (idéntica a la del problema análogo): $(|e_k|\leq\frac{(M/2)h}{L}\big[(1+hL)^k-1\big]=\frac{Mh}{2L}\big[(1+hL)^k-1\big])$.

En $(k=N)$, $(N_h=1)$, y usando $(1+x\leq e^x)$: $((1+hL)^N\leq e^{hLN}=e^L=e^{b+c})$. Por lo tanto:

$$|y(1)-y_N|=|e_N|\leq\frac{Mh}{2(b+c)}\big(e^{b+c}-1\big)\leq\frac{Mh}{2(b+c)}e^{b+c},$$

pues $(e^{b+c}-1$

$$\boxed{|y(1)-y_N|\leq\frac{Mhe^{b+c}}{2(b+c)}} \quad \blacksquare$$

