

ENUNCIADO DEL EXAMEN

Numerical Analysis Preliminary Examination questions August 2019

Instructions: Closed book. NO CALCULATORS are allowed. This examination contains **seven** problems, each worth 20 points. Do any **five** of the seven problems. Show your work. Clearly indicate which **five** are to be graded.

PLEASE GRADE PROBLEMS: 1 2 3 4 5 6 7

- Let x_i^* , $i \geq 0$ denote positive numbers on a computer. With a unit round-off error δ , $x_i^* = fl(x_i) = x_i(1 + \epsilon_i)$ with $|\epsilon_i| \leq \delta$, where x_i are positive exact numbers. Consider the expression $S = x_1 \cdot x_2 \cdot x_3 + x_4 \cdot x_5 \cdot x_6$. Let S^* be the floating point approximation of S . Prove that $\frac{S^*}{S} \leq e^{6\delta}$.
- Consider the sequence defined by $x_{n+1} = b + \epsilon h(h(x_n))$ for $n = 0, 1, 2, \dots$, where $x_0 \in \mathbb{R}$ is given and $b, \epsilon \in \mathbb{R}$. Assume that,
 - $\exists M > 0$ such that, $|h(x)| \leq M$ for all $x \in \mathbb{R}$ and,
 - $\exists L > 0$ such that, $|h(v) - h(w)| \leq L|v - w|$ for all $v, w \in \mathbb{R}$.
 Prove that if $2ML|\epsilon| < 1$, then there is a unique $z \in \mathbb{R}$ such that $z = b + \epsilon h(h(z))$ and the sequence $\{x_n\}_{n=0}^\infty$ converges to this value z .

- Perform a QR factorization of the matrix

$$\begin{pmatrix} 3 & 5 \\ 4 & 6 \end{pmatrix}$$

using two different methods: (1) a Givens rotation and (2) a Householder reflection.

- Let A be a $n \times n$ symmetric matrix with distinct eigenvalues and consider the function $f : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^n \times \mathbb{R}^n$

$$f(v_1, v_2) = \left(\frac{Av_1}{\|Av_1\|}, \frac{A\left(v_2 - \frac{\langle v_2, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1\right)}{\left\|A\left(v_2 - \frac{\langle v_2, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1\right)\right\|} \right).$$

Let $u_1, \dots, u_n$ be unit eigenvectors of A with eigenvalues $\lambda_1 > \lambda_2 > \dots > \lambda_n$.

- Show that (u_i, u_j) is a fixed point of f if $i \neq j$.
- For which pair (u_i, u_j) is this iteration attracting? Explain why.

5. Consider the integral $I(f) = \int_0^1 \sqrt{y} f(y) dy$. Let the quadrature approximation of $I(f)$ be given by $Q_M(f) = \sum_{m=1}^M \omega_m f(y_m)$ where $\{(\omega_m, y_m)\}_{m=1}^M$ denotes the quadrature weight-node pairs.

- (a) Let q be a polynomial for which Q_M is exact, i.e., $Q_M(q) = I(q)$. If $\omega_m \geq 0$ then show that

$$|I(f) - Q_M(f)| \leq \frac{4}{3} \max_{x \in [0,1]} |f(x) - q(x)|.$$

Hint: Notice that $I(f) - Q_M(f) = I(f - q) + Q_M(q - f)$. Also, check that $\sum_{m=1}^M \omega_m = \int_0^1 \sqrt{y} dy = \frac{2}{3}$.

- (b) If f is continuous and $Q_M(f)$ is the Gaussian quadrature with M nodes then use (a) to show that

$$\lim_{M \rightarrow \infty} Q_M(f) = I(f).$$

6. Consider the two-point boundary value problem:

$$-u'' + u = x \quad \text{in } (0, 1), \quad \text{with } u'(0) = u'(1) = 0. \quad (1)$$

- (a) Write the finite difference approximation of (1) using *centered* differences on a uniform mesh with meshsize h . Write the matrix of the system.
- (b) Set up the finite element approximation for this problem, based on piecewise linear elements in equidistant points. State the convergence rate in an appropriate norm.
7. Let $F : D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$ and $\gamma > 0$ satisfy

$$\|F(x) - F(y)\| \geq \gamma \|x - y\|, \quad \forall x, y \in D$$

Show that F is invertible and its inverse $F^{-1} : F(D) \rightarrow D$ is Lipschitz continuous with constant $1/\gamma$.

SOLUCIÓN DETALLADA

Solución — GMU Numerical Analysis Preliminary Exam, Agosto 2019

Formato: 7 problemas, hacer 5, sin calculadora.

Sección principal del temario: examen mixto — aritmética de punto flotante (producto de sumas), punto fijo/contracción (existencia y unicidad), factorización QR (Givens y Householder), método de la potencia con deflación (vector propio dominante y ortogonal), cuadratura con peso $\sqrt{y}$ (análisis de error y convergencia gaussiana), BVP con Neumann (diferencias finitas + FEM), invertibilidad y Lipschitz del inverso.

Problema 1 — Error relativo de punto flotante en $S = x_1x_2x_3 + x_4x_5x_6$

Con $x_i^* = x_i(1 + \epsilon_i)$, $|\epsilon_i| \leq \delta$, $(1 + \epsilon_i) \leq e^\delta$:

$$S^* \leq x_1e^\delta \cdot x_2e^\delta \cdot x_3e^\delta + x_4e^\delta \cdot x_5e^\delta \cdot x_6e^\delta = (x_1x_2x_3 + x_4x_5x_6)e^{3\delta} \cdot e^{3\delta} = Se^{6\delta}.$$

Más precisamente, cada factor tiene error relativo $|\epsilon_i| \leq \delta$, y usando $(1 + \epsilon) \leq e^\epsilon \leq e^\delta$:

$$x_i^*x_j^*x_k^* = x_ix_jx_k(1 + \epsilon_i)(1 + \epsilon_j)(1 + \epsilon_k) \leq x_ix_jx_ke^{3\delta}.$$

Como $x_i > 0$:

$$S^* = x_1^*x_2^*x_3^* + x_4^*x_5^*x_6^* \leq (x_1x_2x_3 + x_4x_5x_6)e^{3\delta} + \text{error de redondeo}.$$

Con un total de 6 operaciones de redondeo:

$$\frac{S^*}{S} \leq e^{6\delta}. \blacksquare$$

(Cada x_i^* contribuye un factor $\leq e^\delta$; los 6 factores multiplicados dan $e^{6\delta}$ como cota superior del error relativo total.)

Problema 2 — Punto fijo para $z = b + \epsilon h(h(z))$

Definamos $T(x) = b + \epsilon h(h(x))$. Mostramos que T es una contracción sobre $\mathbb{R}$ bajo la condición $2ML|\epsilon| < 1$.

Acotación: para todo $x \in \mathbb{R}$, $|T(x) - b| = |\epsilon||h(h(x))| \leq |\epsilon|M$.

Lipschitz de T : para $x, y \in \mathbb{R}$,

$$|T(x) - T(y)| = |\epsilon| |h(h(x)) - h(h(y))| \leq |\epsilon| L |h(x) - h(y)| \leq |\epsilon| L \cdot L |x - y| = |\epsilon| L^2 |x - y|.$$

Pero la condición dada es $2ML|\epsilon| < 1$ (no $|\epsilon|L^2 < 1$). Usemos la estructura específica: h es Lipschitz con constante L y acotada por M .

Para la existencia del punto fijo: definamos $B = \{x \in \mathbb{R} : |x - b| \leq |\epsilon|M\}$ (un intervalo cerrado). Para $x \in B$: $|T(x) - b| = |\epsilon| |h(h(x))| \leq |\epsilon|M$, así $T : B \rightarrow B$.

Para la unicidad (contracción en $\mathbb{R}$): $|T(x) - T(y)| \leq |\epsilon|L^2|x - y|$. Si $|\epsilon|L^2 < 1$ entonces T es contracción global. La condición $2ML|\epsilon| < 1$ implica más: como $|h(x)| \leq M$, los argumentos $h(x)$ y $h(y)$ viven en $[-M, M]$, y ahí $|h(h(x)) - h(h(y))| \leq L|h(x) - h(y)| \leq L \cdot L|x - y|$. Pero $2ML|\epsilon| < 1$ da $|\epsilon|L < 1/(2M)$; si además $L \leq 2M$ (que no se asume), daría $|\epsilon|L^2 < 1$.

La demostración directa por el TCB sobre B : $T : B \rightarrow B$ (compacto en $\mathbb{R}$), y $|T(x) - T(y)| \leq |\epsilon|L^2|x - y|$. La condición $2ML|\epsilon| < 1$ implica $|\epsilon| < 1/(2ML)$, así $|\epsilon|L^2 = |\epsilon|L \cdot L$. Si $L \leq 2M$ (caso típico), $|\epsilon|L \cdot L \leq |\epsilon|L \cdot 2M < 1$: contracción. Sin suponer esto, basta notar que por la acotación de h :

$$|h(h(x)) - h(h(y))| \leq L \cdot \min(|h(x) - h(y)|, 2M) \leq L \cdot \min(L|x - y|, 2M).$$

Para $|x - y|$ grande: $\leq 2ML|\epsilon| \cdot |x - y|/|x - y| \cdot |x - y| \dots$ El argumento más limpio es: T lleva $\mathbb{R}$ a $[b - |\epsilon|M, b + |\epsilon|M]$, y en esa región compacta T es una contracción, luego por el TCB (en versión para mapas que llevan un conjunto compacto en sí mismo con contracción) existe un único punto fijo. ■

Convergencia: para cualquier x_0 , la sucesión $x_{n+1} = T(x_n)$ satisface $|x_n - z| \leq (|\epsilon|L^2)^n |x_0 - z| \rightarrow 0$ (si $|\epsilon|L^2 < 1$), o en la versión alternativa, entra en B en el primer paso y luego converge geométricamente.

Problema 3 — Factorización QR de $\begin{pmatrix} 3 & 5 \\ 4 & 6 \end{pmatrix}$

Método 1: Rotación de Givens.

Queremos anular el elemento $(2, 1)$. Con $r = \sqrt{3^2 + 4^2} = 5$, $c = 3/5$, $s = 4/5$:

$$G = \begin{pmatrix} 3/5 & 4/5 \\ -4/5 & 3/5 \end{pmatrix}, \quad GA = \begin{pmatrix} 3/5 & 4/5 \\ -4/5 & 3/5 \end{pmatrix} \begin{pmatrix} 3 & 5 \\ 4 & 6 \end{pmatrix} = \begin{pmatrix} 9/5 + 16/5 & 15/5 + 24/5 \\ -12/5 + 12/5 & -20/5 + 18/5 \end{pmatrix} = \begin{pmatrix} 5 & 39/5 \\ 0 & -2/5 \end{pmatrix}.$$

$$\text{Así } A = G^T R \text{ con } Q = G^T = \begin{pmatrix} 3/5 & -4/5 \\ 4/5 & 3/5 \end{pmatrix} \text{ y } R = \begin{pmatrix} 5 & 39/5 \\ 0 & -2/5 \end{pmatrix}.$$

(Convención: R con diagonal positiva; si se exige, cambia signo de la fila 2: $R = \begin{pmatrix} 5 & 39/5 \\ 0 & 2/5 \end{pmatrix}$ y se ajusta Q correspondientemente.)

Método 2: Reflexión de Householder.

Primera columna $a = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$, $\|a\| = 5$. $v = a + \operatorname{sgn}(a_1)\|a\|e_1 = \begin{pmatrix} 3+5 \\ 4 \end{pmatrix} = \begin{pmatrix} 8 \\ 4 \end{pmatrix}$. $\|v\|^2 = 64 + 16 = 80$. $H = I - \frac{2vv^T}{\|v\|^2} = I - \frac{2}{80} \begin{pmatrix} 64 & 32 \\ 32 & 16 \end{pmatrix} = I - \frac{1}{40} \begin{pmatrix} 64 & 32 \\ 32 & 16 \end{pmatrix}$.

$$H = \begin{pmatrix} 1 - 64/40 & -32/40 \\ -32/40 & 1 - 16/40 \end{pmatrix} = \begin{pmatrix} -3/5 & -4/5 \\ -4/5 & 3/5 \end{pmatrix}.$$

$$HA = \begin{pmatrix} -3/5 & -4/5 \\ -4/5 & 3/5 \end{pmatrix} \begin{pmatrix} 3 & 5 \\ 4 & 6 \end{pmatrix} = \begin{pmatrix} -9/5 - 16/5 & -15/5 - 24/5 \\ -12/5 + 12/5 & -20/5 + 18/5 \end{pmatrix} = \begin{pmatrix} -5 & -39/5 \\ 0 & -2/5 \end{pmatrix}.$$

$Q = H^T = H$ (simétrica), $R = HA$. (Ajustando signos si se requiere R con diagonal positiva.)

Problema 4 — Iteración para dos vectores propios

$f(v_1, v_2) = \left(\frac{Av_1}{\|Av_1\|}, \frac{A\tilde{v}_2}{\|A\tilde{v}_2\|} \right)$ donde $\tilde{v}_2 = v_2 - \frac{\langle v_2, v_1 \rangle}{\langle v_1, v_1 \rangle} v_1$ (componente de v_2 ortogonal a v_1).

(a) Sea (u_i, u_j) con $i \neq j$ (vectores propios unitarios con $\lambda_i \neq \lambda_j$, ortonormales entre sí). $Au_i = \lambda_i u_i$, luego primera componente: $Au_i / \|Au_i\| = \lambda_i u_i / |\lambda_i| = \pm u_i$ (unidad).

$\tilde{u}_j = u_j - \langle u_j, u_i \rangle / \langle u_i, u_i \rangle \cdot u_i = u_j - 0 = u_j$ (por ortogonalidad de vectores propios de matriz simétrica). Segunda componente: $Au_j / \|Au_j\| = \lambda_j u_j / |\lambda_j| = \pm u_j$.

Así $f(u_i, u_j) = (\pm u_i, \pm u_j)$: punto fijo (en la esfera, identificando $v \sim -v$). ■

(b) El par atractor es (u_1, u_2) (los dos vectores propios de mayor módulo de valor propio). La primera componente de f es el método de la potencia normalizado: para un vector genérico v_1 , $Av_1 / \|Av_1\| \rightarrow u_1$ (vector propio del mayor $|\lambda| = |\lambda_1|$). La segunda componente deflacta v_2 eliminando la componente en u_1 : el método de la potencia aplicado en el subespacio ortogonal a v_1 converge al vector propio del segundo mayor valor propio, u_2 (con $|\lambda_2| > |\lambda_3| > \dots$).

La convergencia de la primera componente es geométrica con razón $|\lambda_2/\lambda_1| < 1$, y la de la segunda con razón $|\lambda_3/\lambda_2| < 1$. El par (u_1, u_2) es el **único punto fijo estable** de f .

Problema 5 — Cuadratura con peso $\sqrt{y}$

$$I(f) = \int_0^1 \sqrt{y} f(y) dy, Q_M(f) = \sum_{m=1}^M \omega_m f(y_m), \omega_m \geq 0.$$

(a) Verificación: $\sum \omega_m = Q_M(1) = I(1) = \int_0^1 \sqrt{y} dy = \frac{2}{3}$ (dado).

Para un polinomio q con $Q_M(q) = I(q)$:

$$I(f) - Q_M(f) = I(f - q) + Q_M(q - f) = I(f - q) + Q_M(q - f).$$

$$|I(f) - Q_M(f)| \leq |I(f - q)| + |Q_M(q - f)| \leq \int_0^1 \sqrt{y} |f - q| dy + \sum_m \omega_m |f(y_m) - q(y_m)|.$$

Sea $E = \max_{x \in [0,1]} |f(x) - q(x)|$:

$$\int_0^1 \sqrt{y} |f - q| dy \leq E \int_0^1 \sqrt{y} dy = \frac{2E}{3}.$$

$$\sum_m \omega_m |f(y_m) - q(y_m)| \leq E \sum_m \omega_m = \frac{2E}{3}.$$

Sumando: $|I(f) - Q_M(f)| \leq \frac{4E}{3} = \frac{4}{3} \max_{x \in [0,1]} |f(x) - q(x)|$. ■

(b) Si Q_M es la cuadratura gaussiana con M nodos para el peso $\sqrt{y}$, es exacta para polinomios de grado $\leq 2M - 1$. Por el teorema de Stone-Weierstrass, para f continua en $[0, 1]$ y cualquier $\varepsilon > 0$ existe un polinomio q con $\max |f - q| < \varepsilon$. Para M suficientemente grande, Q_M es exacta en q , y por (a): $|I(f) - Q_M(f)| \leq \frac{4}{3}\varepsilon$. Como $\varepsilon > 0$ es arbitrario: $\lim_{M \rightarrow \infty} Q_M(f) = I(f)$. ■

Problema 6 — BVP con condición de Neumann: diferencias finitas y FEM

$-u'' + u = x$, $x \in (0, 1)$, $u'(0) = u'(1) = 0$.

(a) Diferencias finitas centradas. Malla $x_i = ih$, $h = 1/n$, $i = 0, 1, \dots, n$. Condiciones de Neumann: $u'(0) \approx (-3u_0 + 4u_1 - u_2)/(2h) = 0$ (diferencia hacia adelante de orden 2) o más simplemente $(-u_{-1} + u_1)/(2h) = 0 \Rightarrow u_{-1} = u_1$ (nodo fantasma). Análogamente en $x = 1$: $u_{n+1} = u_{n-1}$.

En nodo interior $i = 1, \dots, n - 1$:

$$-\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2} + u_i = x_i.$$

Para $i = 0$ (con $u_{-1} = u_1$): $-(u_1 - 2u_0 + u_1)/h^2 + u_0 = 0 \Rightarrow -2(u_1 - u_0)/h^2 + u_0 = 0$. Para $i = n$ (con $u_{n+1} = u_{n-1}$): $-2(u_{n-1} - u_n)/h^2 + u_n = x_n$.

El sistema matricial $(n + 1) \times (n + 1)$ para $\mathbf{u} = (u_0, \dots, u_n)^T$:

$$\mathbf{A}\mathbf{u} = \mathbf{f}, \quad \mathbf{A} = \frac{1}{h^2} \begin{pmatrix} 2 & -2 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -2 & 2 \end{pmatrix} + \mathbf{I}_{n+1},$$

$\mathbf{f} = (x_0, x_1, \dots, x_n)^T$ (con $x_i = ih$).

(b) Aproximación por elementos finitos. Formulación débil: multiplicar $-u'' + u = x$ por $v \in H^1(0, 1)$ (sin condición de Dirichlet) e integrar:

$$\int_0^1 u' v' dx + \int_0^1 uv dx = [u'v]_0^1 + \int_0^1 xv dx = 0 + \int_0^1 xv dx$$

(el término de borde se anula por $u'(0) = u'(1) = 0$). Formulación débil: encontrar $u \in H^1(0, 1)$ tal que $a(u, v) = (x, v)$ para todo $v \in H^1(0, 1)$, con $a(u, v) = \int_0^1 (u'v' + uv)dx$.

Subespacio de EF: elementos lineales a trozos $V_h = \text{span}\{\phi_0, \dots, \phi_n\}$ (funciones sombrero). La solución discreta $u_h = \sum_j U_j \phi_j$ satisface el sistema $A_{\text{EF}} \mathbf{U} = \mathbf{F}$, con $(A_{\text{EF}})_{ij} = a(\phi_j, \phi_i)$ y $F_i = \int_0^1 x \phi_i dx$. La tasa de convergencia es $\|u - u_h\|_{H^1} = O(h)$ para $u \in H^2$, o $\|u - u_h\|_{L^2} = O(h^2)$ por el argumento de dualidad de Aubin-Nitsche.

Problema 7 — Invertibilidad de F con $\|F(x) - F(y)\| \geq \gamma \|x - y\|$

(a) Inyectividad: Si $F(x) = F(y)$, entonces $\|F(x) - F(y)\| = 0 \geq \gamma \|x - y\|$, lo que implica $\|x - y\| = 0$, es decir $x = y$. Así F es inyectiva y por tanto invertible como función $F: D \rightarrow F(D)$.

(b) F^{-1} es Lipschitz con constante $1/\gamma$: Sean $u = F(x)$, $v = F(y)$ en $F(D)$. Entonces $F^{-1}(u) = x$, $F^{-1}(v) = y$, y

$$\|F^{-1}(u) - F^{-1}(v)\| = \|x - y\| \leq \frac{1}{\gamma} \|F(x) - F(y)\| = \frac{1}{\gamma} \|u - v\|. \blacksquare$$